

VNiVERSiDAD D SALAMANCA

Guía para elaborar una revisión sistemática de la literatura (SLR)

Planificación, búsqueda, selección, síntesis, publicación y uso responsable de la IA

Daniel H. de la Iglesia

Universidad de Salamanca

1ª Edición • 2026

Índice de contenidos

I Fundamentos **3**

1 Qué es una revisión sistemática de la literatura **5**
1.1 Las cuatro dimensiones (Codina, 2015) . . . 5
1.2 Origen y comunidades . . . 5
1.3 Revisión narrativa frente a revisión sistemática . . . 6
1.4 ¿Sistemática o sistematizada? . . . 6
1.5 Ventajas y coste . . . 6

2 Tipos de revisión y cuál elegir **7**
2.1 SLR frente a mapeo sistemático . . . 8
2.2 Revisión sistemática frente a meta-análisis . . . 8

3 Estándares y guías que debes conocer **9**
3.1 PRISMA 2020 en detalle . . . 10
3.2 Extensiones de PRISMA útiles en informática . . . 10
3.3 SEGRESS: PRISMA adaptado a la ingeniería del software . . . 10
3.4 ACM SIGSOFT Empirical Standards . . . 11
3.5 SALSA y PSALSAR . . . 11

II Fases de la revisión **13**

4 Fase 1. Planificación: de la idea al protocolo **15**
4.1 Paso 0. ¿Hace falta esta revisión? . . . 15
4.2 Paso 1. Preguntas de investigación . . . 15
4.3 Paso 2. Delimitar el ámbito con PICOC . . . 17
4.4 Paso 3. Escribir el protocolo . . . 17
4.5 Paso 4. Registrar o publicar el protocolo . . . 18
4.6 Equipo y tiempos . . . 18
4.7 Errores frecuentes en esta fase . . . 18

5 Fase 2a. Búsqueda: fuentes, cadenas y documentación **19**
5.1 Dónde buscar . . . 19
5.2 Construir la cadena de búsqueda . . . 21
5.3 Snowballing . . . 22
5.4 Literatura gris . . . 22
5.5 Qué documentar (PRISMA-S) . . . 22
5.6 Errores frecuentes . . . 22
5.7 Validación y registro operativo . . . 22

6 Fase 2b. Selección de estudios y evaluación de la calidad **25**

6.1 Criterios de inclusión y exclusión . . . 25
6.2 Las fases de cribado . . . 26
6.3 Acuerdo entre revisores . . . 26
6.4 Evaluación crítica: calidad, riesgo de sesgo y certeza . . . 27
6.5 Errores frecuentes . . . 28

7 Fase 2c. Extracción de datos y síntesis **31**
7.1 El formulario de extracción . . . 31
7.2 Trazabilidad . . . 32
7.3 Síntesis . . . 32
7.4 Representar los datos . . . 32
7.5 Errores frecuentes . . . 33
7.6 De los datos a una respuesta argumentada . . . 33

8 Fase 3. Redacción y publicación **37**
8.1 Estructura recomendada (Kitchenham et al., 2015; PRISMA 2020) . . . 38
8.2 Limitaciones y amenazas a la validez . . . 38
8.3 Dónde publicar . . . 39
8.4 Qué esperar de la revisión por pares . . . 39

III Herramientas e IA **41**

9 Herramientas **43**
9.1 Aprendizaje activo y criterio de parada . . . 43
9.2 Condiciones que debes verificar . . . 44

10 IA generativa en una SLR: qué puede hacer y cómo declararlo **45**
10.1 Qué dice la evidencia, fase por fase . . . 46
10.2 Protocolo de uso responsable . . . 47
10.3 Guías y estándares . . . 47
10.4 Qué exigen las editoriales . . . 48
10.5 Ejemplo de párrafo de declaración . . . 48

IV Práctica **51**

11 Caso práctico guiado **53**
11.1 1. Pregunta y PICOC . . . 53
11.2 2. Conjunto de semi-referencia . . . 54
11.3 3. Fuentes y restricciones . . . 54
11.4 4. Cadena de búsqueda, iterada . . . 54
11.5 5. Criterios de selección y fases . . . 54
11.6 6. Calidad, extracción y síntesis . . . 55
11.7 Cómo lo harías hoy, con lo que añade esta guía . . . 55
11.8 Los errores que más vemos en doctorandos . . . 55
11.9 Ejercicio completo reproducible: datos ficticios . . . 56

12 Plantillas y listas de control **57**
12.1 Plantilla de protocolo . . . 57
12.2 Ficha de extracción (columnas de la hoja de cálculo) . . . 58
12.3 Hoja de cribado (una fila por registro) . . . 59
12.4 Checklist de reporte abreviado (PRISMA 2020 + SEGRESS) . . . 59
12.5 Cronograma orientativo (SLR de doctorado, 300 a 1.500 candidatos) . . . 60
12.6 Plantillas descargables . . . 60

V Referencias **61**

13 Referencias y recursos **63**
13.1 Guías metodológicas . . . 63
13.2 Reporte y registro . . . 64
13.3 IA en revisiones . . . 64
13.4 Ejemplos y lecturas en español . . . 64
13.5 Otros recursos . . . 65
13.6 Evaluación crítica y certeza . . . 65

VI Información **67**

14 Acerca de **69**
14.1 Cómo está hecho este libro . . . 69
14.2 Sobre el autor . . . 69

15 Créditos y licencias **71**
15.1 Créditos del proyecto . . . 71
15.2 Agradecimientos . . . 71
15.3 Licencia del libro . . . 71
15.4 Recursos externos . . . 72
15.5 Código y herramientas . . . 72
15.6 Figuras y datos de esta edición . . . 72

16 Cómo citar **73**
16.1 Cita recomendada (APA 7.ª edición) . . . 73
16.2 BibTeX . . . 73

17 Bibliografía **75**

Esta guía explica, paso a paso, cómo planificar, ejecutar y publicar una revisión sistemática de la literatura (SLR) o un mapeo sistemático en ingeniería e informática. Está pensada para doctorandos e investigadores que abordan su primera revisión.

Cómo usar esta guía

Si es tu primera SLR, lee los capítulos en orden. Si ya tienes un tema y necesitas empezar, ve directamente a las fases (planificación, búsqueda, selección, extracción y redacción) y usa las plantillas del final. Cada fase cierra con los errores más frecuentes que vemos en doctorandos. Los dos documentos que conviene tener siempre a mano son las guías de proceso de Kitchenham and Charters [KC07] y la declaración de reporte PRISMA 2020 de Page *et al.* [PMB+21].

Itinerario rápido

1. **Fundamentos**: qué es una SLR, qué tipos de revisión existen y qué estándares (PRISMA 2020, SEGRESS, Kitchenham, Petersen) tendrás que cumplir.
2. **Fases de la revisión**: planificación y protocolo, búsqueda, selección y calidad, extracción y síntesis, redacción y publicación.
3. **Herramientas e IA**: qué herramienta usar en cada fase y cómo usar (y declarar) la IA generativa sin comprometer el rigor.
4. **Práctica**: un caso guiado y las plantillas de protocolo, ficha de extracción, hoja de cribado, checklist y cronograma.
5. **Referencias**: las guías metodológicas, los estándares de reporte y lecturas recomendadas en español.

Contenido

Parte	Capítulos
Fundamentos	*Qué es una SLR* · *Tipos de revisión* · *Estándares y guías*
Fases	*Planificación* · *Búsqueda* · *Selección y calidad* · *Extracción y síntesis* · *Redacción y publicación*
Herramientas e IA	*Herramientas* · *IA generativa en una SLR*
Práctica	*Caso práctico guiado* · *Plantillas y listas de control*
Referencias	*Referencias y recursos*

Nota

Las herramientas y políticas cambian. Consulta las fuentes oficiales y registra fecha, versión y condiciones. Revisión metodológica y visual: 16 de octubre de 2026.

Versión PDF

También puedes descargar la versión imprimible del libro:

- Descargar PDF

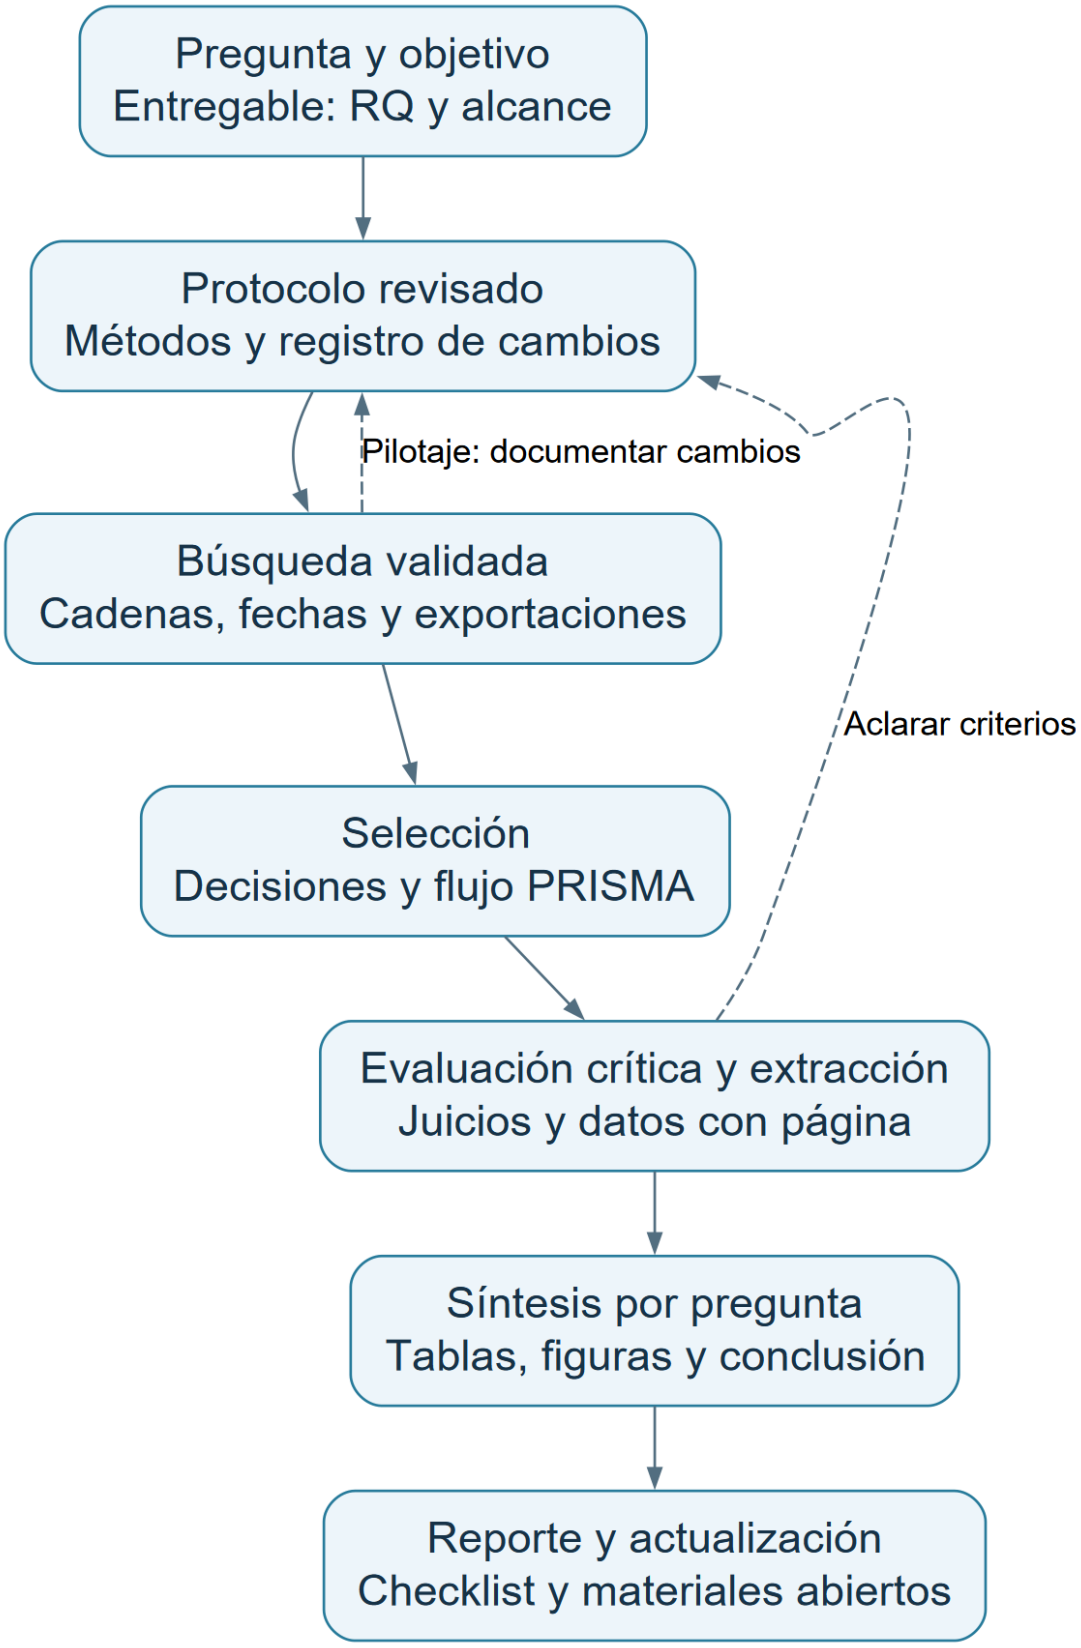


Figura 1: Mapa del proceso y entregables. Las flechas discontinuas representan revisiones documentadas del protocolo. Elaboración propia, CC BY 4.0.

Parte I

Fundamentos

CAPÍTULO 1

Qué es una revisión sistemática de la literatura

Una SLR es un estudio secundario que identifica, evalúa e interpreta toda la evidencia disponible sobre una pregunta de investigación concreta, siguiendo un método explícito, imparcial y (hasta cierto punto) repetible (Kitchenham & Charters, 2007). A diferencia de un trabajo original, la unidad de análisis no son personas o sistemas, sino artículos previos: el revisor plantea una pregunta, recoge datos en forma de estudios, los analiza y extrae una conclusión.

Su objetivo es decir qué se sabe de un tema, qué se ha investigado y qué sigue sin resolverse. La ventaja decisiva frente a otras revisiones es que otro investigador puede replicarla y comprobar si llega a la misma conclusión (Sáenz, 2001).

1.1 Las cuatro dimensiones (Codina, 2015)

- **Sistemática**: no es arbitraria ni subjetiva; examina la mejor producción científica disponible con las mejores fuentes.
- **Completa**: usa sistemas de información que dan acceso al grueso de la producción internacional de calidad y no descarta ni incluye nada sin criterios explícitos.
- **Explícita**: publica las fuentes, los criterios de búsqueda y los de selección y exclusión.
- **Reproducible**: al ser sistemática y explícita, otros pueden seguir los pasos y contrastar los resultados.

1.2 Origen y comunidades

Las SLR nacieron en Medicina. La Colaboración Cochrane, fundada en 1993, publica revisiones en la *Cochrane Database of Systematic Reviews*. La Campbell Collaboration es su hermana en Ciencias Sociales (Petticrew & Roberts, 2005).

En Ingeniería del Software la comunidad de *Evidence-Based Software Engineering* (EBSE) adaptó el método a partir de 2004, con las guías de Kitchenham (2004) y Kitchenham & Charters (2007), que siguen siendo la referencia que se cita en la mayoría de SLR de informática. Desde entonces el campo ha añadido guías propias para mapeos (Petersen et al., 2008, 2015), *snowballing* (Wohlin, 2014), literatura gris (Garousi et al., 2019) y reporte (SEGRESS, 2023). La sección de estándares las recorre una a una.

1.3 Revisión narrativa frente a revisión sistemática

Característica	Revisión narrativa	Revisión sistemática
Pregunta de investigación	Amplia, no estructurada	Estructurada, clara y concreta
Búsqueda bibliográfica	No detallada ni sistemática; alta probabilidad de sesgo	Detallada, sistemática y explícita
Selección de artículos	Sin criterios; no reproducible	Criterios explícitos aplicados de forma uniforme a todos los artículos
Valoración de la calidad	No hay	Evaluación crítica de la calidad metodológica de cada estudio
Síntesis	Resumen subjetivo, cualitativo	Basada en la calidad de los estudios; a menudo cuantificada
Interpretación	A veces basada en evidencia, a menudo en opinión	Generalmente basada en la evidencia

Adaptado de Martín Rodero (2014).

1.4 ¿Sistemática o sistematizada?

Una revisión sistemática puede sintetizar estudios cuantitativos, cualitativos o mixtos. **No requiere metaanálisis**: la elección de síntesis depende de la pregunta, los diseños y los datos disponibles. Una síntesis narrativa o temática también puede seguir un método sistemático.

Grant y Booth describen las revisiones sistematizadas como trabajos que incorporan algunos elementos de una revisión sistemática, pero no necesariamente todos. La distinción debe explicarse por los métodos realmente aplicados y sus limitaciones, no por la disciplina ni por la ausencia de estadística [GB09, Cochrane].

1.5 Ventajas y coste

Una metodología bien definida reduce el sesgo del revisor (aunque no protege del sesgo de publicación de los estudios primarios), permite ver si un fenómeno es robusto en distintos contextos y, con estudios cuantitativos, combinar datos en un meta-análisis que detecta efectos que los estudios pequeños no ven. El precio es el esfuerzo: una SLR exige mucho más tiempo que una revisión tradicional, y conviene saberlo antes de empezar.

CAPÍTULO 2

Tipos de revisión y cuál elegir

Elige el diseño según el objetivo: clasificar el campo (mapeo), delimitar conceptos y tipos de evidencia (scoping), o responder una pregunta concreta mediante síntesis crítica (SLR). El metaanálisis es una técnica de síntesis que puede formar parte de una SLR cuando los estudios son suficientemente compatibles. La experiencia previa del equipo influye en la preparación necesaria, pero no determina el diseño.

Tipo	Pregunta típica	Qué produce	Evaluación de calidad	Guía de referencia
Revisión sistemática (SLR)	¿Qué se sabe sobre X? ¿Qué soluciones existen y cómo funcionan?	Síntesis en profundidad de las evidencias de una pregunta concreta	Sí, obligatoria	Kitchenham & Charters (2007); PRISMA 2020; SEGRESS
Mapeo sistemático (SMS)	¿Cuánto se ha publicado, quién, dónde y sobre qué subtemas?	Clasificación y recuento de la literatura; mapas, *bubble plots*, tendencias	Normalmente no, o ligera	Petersen et al. (2008, 2015); PRISMA-ScR
Meta-análisis	¿Cuál es el efecto combinado de la intervención X?	Estimación estadística agregada (tamaño del efecto)	Sí, con riesgo de sesgo	Cochrane Handbook; PRISMA 2020
Scoping review	¿Qué conceptos, tipos de evidencia y lagunas hay en un campo emergente?	Mapa conceptual del área; a menudo precede a una SLR	Opcional	PRISMA-ScR (Tricco et al., 2018); JBI
Revisión multivocal (MLR)	¿Qué dicen la academia **y** la práctica profesional (blogs, informes, vídeos)?	SLR que incorpora literatura gris	Sí, con criterios para fuentes grises	Garousi et al. (2019)
Estudio terciario / umbrella review	¿Qué dicen las revisiones sistemáticas ya publicadas?	Síntesis de revisiones (la unidad es la SLR)	Sí, con AMSTAR 2 o ROBIS	Kitchenham et al. (2009, 2010)
Revisión rápida	Igual que una SLR, con menos recursos y plazo corto	Síntesis simplificada; documentar los atajos	Simplificada	Cochrane Rapid Reviews Methods Group

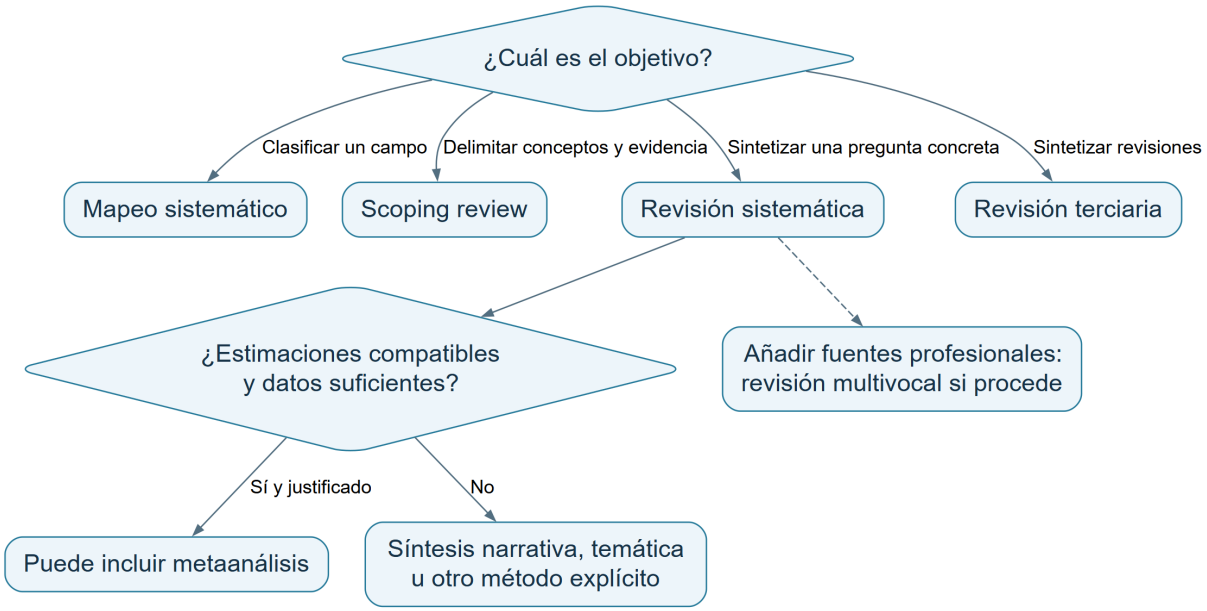


Figura 2.1: Elegir según el objetivo. Los diseños pueden combinarse con justificación; el metaanálisis es una técnica de síntesis. Elaboración propia, CC BY 4.0.

2.1 SLR frente a mapeo sistemático

La diferencia se puede resumir así: la revisión sistemática detalla el estado de la cuestión y busca resultados que respondan a preguntas abiertas; el mapeo resume a grandes rasgos e identifica el volumen de evidencias, los tipos de investigación y los resultados disponibles. En la práctica el término «revisión sistemática» se usa indistintamente para ambos, y los dos pueden publicarse en revista y servir como capítulo de una tesis o TFM.

Combinar ambos diseños puede ser útil si responde a los objetivos y recursos disponibles: un mapeo inicial dice dónde está la masa de la literatura y una SLR posterior profundiza en el subconjunto que responde a tu pregunta. Las preguntas de mapeo son del tipo «¿cuántos estudios se publicaron por año?», «¿quiénes son los autores más activos?», «¿en qué dominios se ha aplicado?» o, en una revisión sobre LLM en ingeniería del software, «¿qué modelos se usan y en qué tareas?» (Hou et al., 2024); las de SLR son del tipo «¿qué soluciones se han usado para X?» y «¿cómo abordan X?».

2.2 Revisión sistemática frente a meta-análisis

Una SLR responde a una pregunta recopilando y resumiendo toda la evidencia empírica con un método explícito; un meta-análisis es el uso de métodos estadísticos para combinar los resultados de estudios similares y obtener estimaciones más precisas. El metaanálisis puede formar parte de una SLR, pero no toda SLR lo contiene (Kitchenham & Charters, 2007; Mujica-Sequera, 2022). En ingeniería e informática el meta-análisis es poco frecuente porque los estudios primarios rara vez miden las mismas variables con diseños comparables; cuando lo hagas, evita el *vote counting* (contar cuántos estudios dan positivo), práctica que los ACM SIGSOFT Empirical Standards desaconsejan explícitamente.

CAPÍTULO 3

Estándares y guías que debes conocer

Para una SLR en informática hoy necesitas tres cosas: una guía de **proceso** (Kitchenham & Charters para SLR; Petersen para mapeos), una guía de **reporte** (PRISMA 2020 o su adaptación SEGRESS) y, si publicas en una sede ACM/IEEE, el **estándar empírico** de SIGSOFT. Los marcos SALSA y PSALSAR sirven para comprobar que el diseño cubre las cuatro dimensiones (sistemática, completa, explícita, reproducible).

Guía	Año	Para qué sirve	Dónde
Kitchenham & Charters, EBSE-2007-01	2007	Proceso completo de una SLR en ingeniería del software: planificación, conducción y reporte	Informe técnico
Kitchenham, Budgen & Brereton, *Evidence-Based Software Engineering and Systematic Reviews*	2015	Libro que sustituye a los informes de 2004 y 2007; incluye estudios primarios, síntesis y traslación de conocimiento	Routledge
Petersen et al., EASE	2008	Proceso del mapeo sistemático: preguntas, búsqueda, cribado, *keywording* de resúmenes, extracción y mapa	PDF
Petersen, Vakkalanka & Kuzniarz, IST	2015	Actualización de las guías de mapeo tras analizar cómo se aplicaban; concluye que las guías de 2008 «no bastan por sí solas»	EBSE
Wohlin, EASE	2014	*Snowballing* hacia atrás y hacia delante como estrategia de búsqueda; premio al artículo más influyente EASE 2024	EASE 2024 award
Garousi, Felderer & Mäntylä, IST	2019	Literatura gris y revisiones multivocales (MLR)	arXiv
PRISMA 2020 (Page et al., BMJ)	2021	Lista de 27 ítems para **reportar** una revisión y diagrama de flujo; no evalúa la calidad de la revisión	prisma-statement.org
SEGRESS (Kitchenham, Madeyski & Budgen, IEEE TSE)	2023	Adaptación de PRISMA 2020 a los estudios secundarios de ingeniería del software: SLR, mapeos, terciarios, cualitativos	Checklist
ACM SIGSOFT Empirical Standards (Ralph et al.)	2020–2021	Lo que un revisor de ICSE/FSE/EMSE esperará ver en una revisión sistemática	Estándar Systematic Reviews

3.1 PRISMA 2020 en detalle

PRISMA (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*) nació en 2009 y se actualizó en 2021 (Page et al., BMJ 2021;372:n71). Su objetivo es que el informe de la revisión sea completo y transparente; sirve también para evaluar críticamente revisiones publicadas, pero **no** es un instrumento de calidad metodológica. Consta de un checklist de 27 ítems en siete secciones, un checklist de 12 ítems para el resumen y un diagrama de flujo.

Qué cambió respecto a 2009 y conviene tener presente:

- El ítem de búsqueda exige las estrategias completas de **todas** las bases de datos, registros y webs consultadas, no solo una de ejemplo.
- Hay que indicar cuántos revisores cribaron cada registro, si trabajaron de forma independiente y qué herramientas de automatización se usaron.
- La síntesis se desglosa en seis subítems de métodos y cuatro de resultados.
- Se añaden ítems sobre certeza de la evidencia, conflictos de interés y disponibilidad de datos, código y materiales.
- El diagrama de flujo tiene dos brazos: bases de datos y registros, y «otros métodos» (búsqueda por citas, webs, organizaciones), que se añade solo si se usaron. Hay cuatro plantillas oficiales y una aplicación web gratuita (Haddaway et al., 2022) que genera el diagrama en PDF, PNG o SVG.

Existe una traducción oficial al español de la declaración (Rev Esp Cardiol 2021;74(9):790–799), y la web de PRISMA enlaza también el checklist y el diagrama en español.

3.2 Extensiones de PRISMA útiles en informática

- **PRISMA-S** (Rethlefsen et al., 2021): 16 ítems para documentar la búsqueda (nombre de cada base, cadena completa, límites, filtros, fechas, revisión por pares de la estrategia, total de registros y deduplicación). Es la mejor lista de control para la sección de búsqueda de cualquier SLR.
- **PRISMA-ScR** (Tricco et al., 2018): 20 ítems esenciales para scoping reviews; SEGRESS la recomienda también para mapeos.
- **PRISMA-P** (Moher et al., 2015): 17 ítems para redactar el protocolo.

3.3 SEGRESS: PRISMA adaptado a la ingeniería del software

SEGRESS (IEEE TSE 49(3), 2023) toma los 27 ítems de PRISMA 2020, los combina con PRISMA-S, PRISMA-P y PRISMA-ScR, e indica para cada ítem a qué tipo de estudio secundario aplica (SLR cuantitativa, mapeo, terciario, cualitativo, mixto). Sustituye «evaluación de calidad» por «riesgo de sesgo» y «amenazas a la validez» por «limitaciones». Si vas a publicar en IST, JSS o TSE, es el checklist que debes seguir.

3.4 ACM SIGSOFT Empirical Standards

El estándar para revisiones sistemáticas lista atributos **esenciales** (tipo de revisión identificado; búsqueda replicable paso a paso con los términos; criterios de selección claros; extracción y síntesis detalladas; esquema de codificación; cadena de evidencia; conclusiones útiles para profesionales) y **deseables** (protocolo, búsquedas y dataset como material suplementario; *snowballing* y preprints para mitigar sesgo; evaluación de calidad definida a priori; dos analistas con medida de acuerdo; diagrama PRISMA; meta-análisis sin *vote counting*). Nombra dos antipatrones: la «lista de la compra» de artículos sin síntesis y usar la sede de publicación como sustituto de la calidad.

3.5 SALSA y PSALSAR

Grant & Booth (2009) proponen el marco SALSA (*Search, AppraisaL, Synthesis, Analysis*) para comprobar si un método de revisión cumple las cuatro dimensiones. Mengist et al. (2020) lo amplian a PSALSAR añadiendo el **protocolo** al principio y el **reporte** (con PRISMA) al final, en seis pasos: Protocol, Search, Appraisal, Synthesis, Analysis, Report. Es un buen esqueleto para la sección de metodología de tu artículo.

Parte II

Fases de la revisión

CAPÍTULO 4

Fase 1. Planificación: de la idea al protocolo

La planificación termina con un protocolo escrito y revisado por alguien que no sea tú. Define preguntas, criterios, fuentes, estrategia de búsqueda, extracción y evaluación crítica antes de la búsqueda definitiva. Las búsquedas exploratorias y los pilotajes permiten afinar el protocolo. Un cambio posterior puede ser necesario: registra fecha, motivo, fase y efecto, y distingue decisiones previas de decisiones informadas por los resultados.

4.1 Paso 0. ¿Hace falta esta revisión?

Hazte dos preguntas (Kitchenham & Charters, 2007). Primera: ¿es necesaria? Busca en Google Scholar, Scopus y Web of Science con «systematic review», «literature review», «mapping study», «survey» y «state of the art» junto a tu tema. Si ya existe una SLR reciente, solo tiene sentido repetirla si está claramente sesgada o anticuada porque han aparecido estudios nuevos (Petticrew & Roberts, 2005); si no, replantea el tema o conviértela en una actualización. Segunda: ¿tienes los recursos? Una SLR cuesta meses; necesitas tiempo, acceso a las bases de datos (la biblioteca de tu universidad), al menos un segundo revisor y una idea clara de quién va a usar los resultados y cómo.

Antes de seguir fija cuatro cosas: alcance, tiempos, beneficios previstos y dónde piensas publicar, porque la sede condiciona la extensión y el checklist que tendrás que cumplir.

4.2 Paso 1. Preguntas de investigación

La pregunta es el corazón del protocolo: de ella se derivan el título, los objetivos, la cadena de búsqueda y la ficha de extracción. Debe ser clara y específica, y su respuesta debe exigir explicación (nunca un sí o no). Comprueba su pertinencia con el acrónimo FINER:

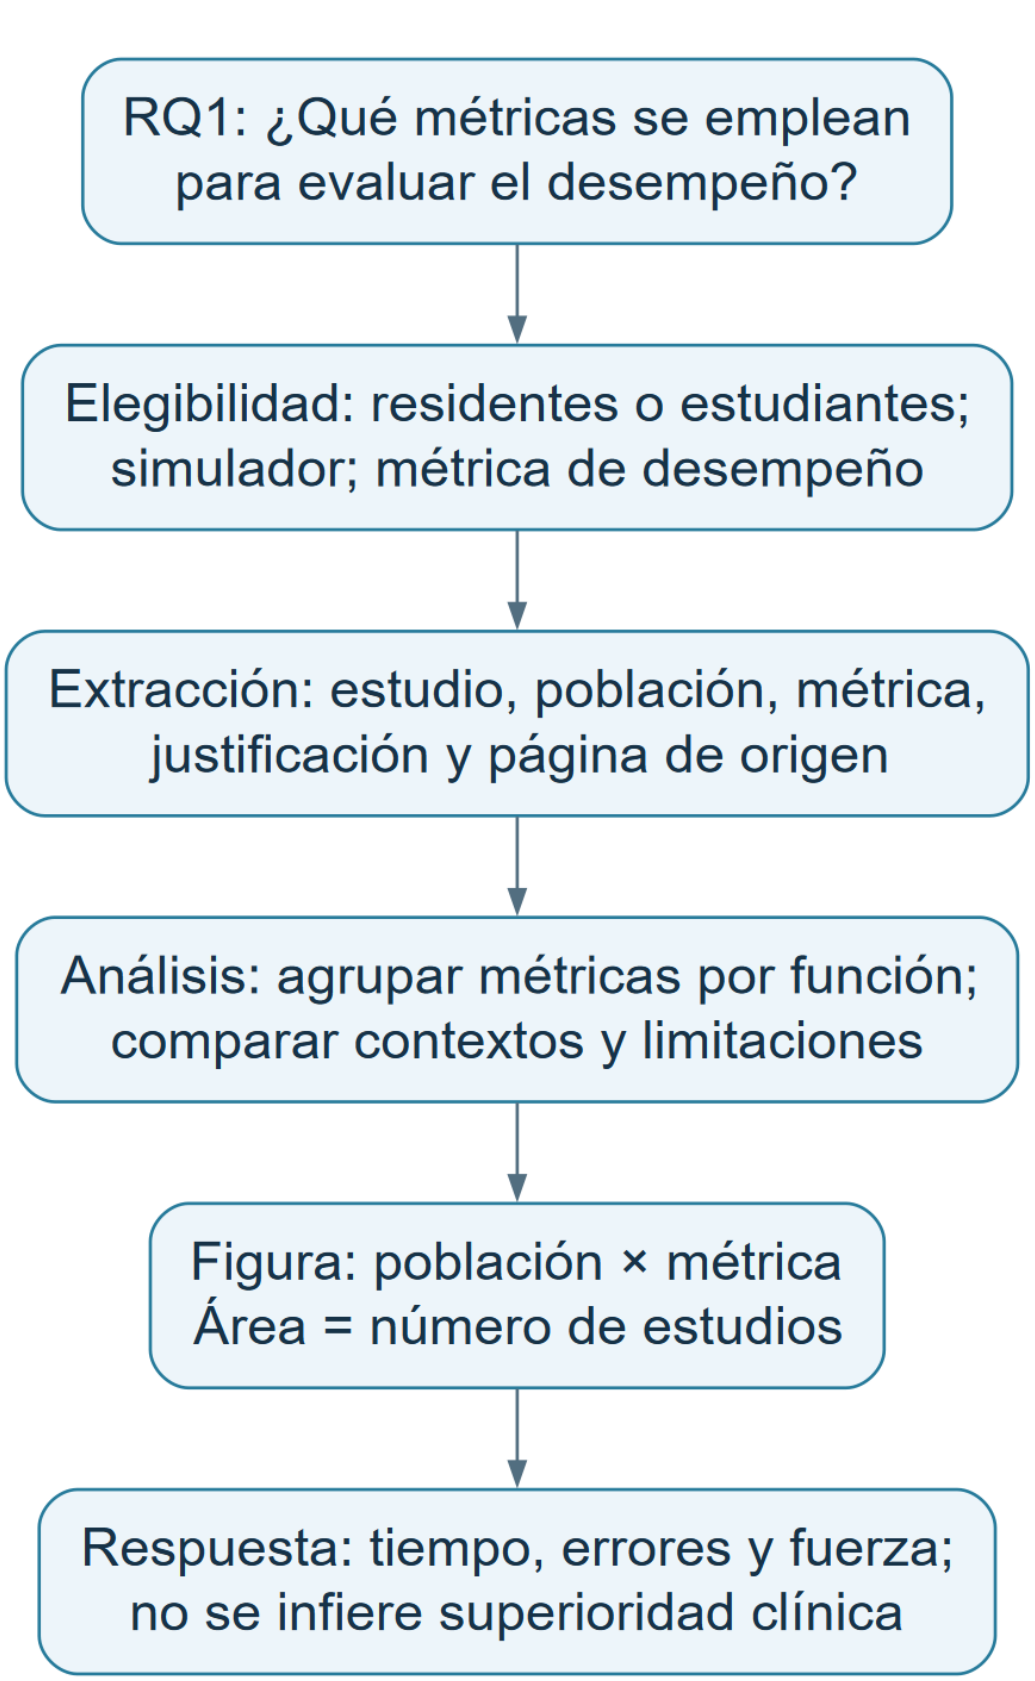


Figura 4.1: De RQ1 a la conclusión en el ejercicio ficticio. Cada decisión debe rastrearse hasta su origen. Elaboración propia, CC BY 4.0.

Criterio	Pregunta que debes hacerte
Factible	¿Tengo recursos, acceso y tiempo para responderla?
Interesante	¿Me interesa de verdad a mí y a mi comunidad?
Novedosa	¿Confirma, refuta o amplía hallazgos previos?
Ética	¿Responderla puede dañar a alguien?
Relevante	¿Aporta algo al conocimiento científico o a la práctica?

Las preguntas de un mapeo categorizan (»¿cuántos estudios por año?», «¿qué sedes?», «¿qué dominios?», «¿qué tipo de contribución: framework, herramienta, método?»). Las de una SLR profundizan (»¿qué soluciones se han propuesto para X?», «¿cómo se evaluaron?», «¿qué limitaciones reportan?»). Conviene numerarlas (MQ1… para mapeo, RQ1… para SLR) y que cada columna de la ficha de extracción responda a una de ellas.

4.3 Paso 2. Delimitar el ámbito con PICOC

PICOC (Petticrew & Roberts, 2005; Kitchenham & Charters, 2007) estructura la pregunta y, de paso, da los términos de búsqueda:

Elemento	Pregunta	Ejemplo (Hou et al., 2024)
Populat	¿Quién o qué?	Estudios primarios que aplican un LLM a una tarea de ingeniería del software (generación de código, reparación de programas, pruebas, detección de vulnerabilidades…)
Interve	¿Qué? ¿Cómo?	Grandes modelos de lenguaje (GPT, Codex, CodeBERT, LLaMA…) y las técnicas para adaptarlos: *prompting*, ajuste fino, recuperación de contexto
Compa	¿Con qué se compara?	Entre arquitecturas de modelo, estrategias de datos y técnicas de optimización; no hay grupo de control
Outcon	¿Qué se quiere conseguir o mejorar?	Qué modelos se usan, cómo se preparan los datos, cómo se optimiza y evalúa el rendimiento y en qué tareas funcionan mejor
Contex	¿En qué organización y circunstancias?	Investigación académica en ingeniería del software, incluidos preprints de arXiv, de 2017 a enero de 2024

En informática la «población» suele ser un tipo de sistema, técnica o rol (desarrolladores, estudiantes de programación), y la comparación a menudo no existe; déjalo explícito. Para revisiones cualitativas puedes usar SPIDER (*Sample, Phenomenon of Interest, Design, Evaluation, Research type*).

4.4 Paso 3. Escribir el protocolo

Un protocolo mínimo tiene ocho elementos: preguntas y objetivos, criterios de inclusión, criterios de exclusión, bases de datos y motores, términos de búsqueda, procedimiento de búsqueda y extracción (iterado en etapas), evaluación de la calidad y síntesis de resultados. Añade además: número de revisores y cómo resolveréis desacuerdos, la ficha de extracción, el plan de síntesis, el cronograma y la estrategia de difusión. PRISMA-P (17 ítems) sirve como lista de control; la plantilla del final de esta guía la sigue.

Pide a tu director o a un colega que revise el protocolo antes de ejecutarlo. Kitchenham & Charters lo marcan como actividad propia de la planificación («evaluar el protocolo»), y es el momento más barato para corregir una pregunta mal planteada.

4.5 Paso 4. Registrar o publicar el protocolo

Registrar el protocolo antes de la ejecución mejora la transparencia y permite contrastar el plan con lo realizado; no garantiza por sí solo ausencia de sesgo. PRISMA 2020 pide informar del registro y del acceso al protocolo, o indicar que no existen. Un depósito público y un registro prospectivo no son equivalentes. Opciones:

- PROSPERO (Universidad de York, gratuito): solo acepta revisiones con resultados relevantes para la salud humana; no sirve para la mayoría de SLR de informática o educación, y excluye scoping reviews. Relanzado en marzo de 2025 con publicación automática tras la aprobación de los autores.
- OSF Registries (gratuito, con DOI, cualquier disciplina): la opción más usada fuera de salud; tiene plantilla «Generalized Systematic Review» válida para SLR, scoping y meta-análisis.
- INPLASY (consulta tarifas y condiciones vigentes) y Research Registry (de pago): aceptan cualquier campo.
- Depósito abierto en Zenodo, Figshare o arXiv: práctica habitual en ingeniería del software, con identificador persistente y fecha, aunque sin revisión; Zenodo y Figshare permiten DOI, mientras que arXiv proporciona un identificador arXiv.

Solo el 31,5 % de los 537 estudios secundarios de ingeniería del software publicados entre 2013 y 2023 comparten sus artefactos (protocolo, búsquedas, datos), y apenas el 12 % lo hace en un repositorio permanente (Huotala, Kuutila & Mäntylä, 2025). Hacerlo bien te diferencia.

4.6 Equipo y tiempos

Una SLR no es un trabajo de una sola persona: PRISMA 2020 pide indicar cuántos revisores cribaron y si lo hicieron de forma independiente, y los Empirical Standards consideran deseable que haya dos analistas con una medida de acuerdo. Para un doctorando lo habitual es que el director o un compañero haga de segundo revisor, al menos sobre una muestra. En cuanto a tiempos, cuenta con 4 a 9 meses para una SLR completa en un área con varios cientos de candidatos; la fase que más se subestima es la lectura a texto completo y la extracción.

4.7 Errores frecuentes en esta fase

Errores frecuentes en esta fase

- Empezar a buscar sin protocolo y «reconstruirlo» después.
- Preguntas tan amplias que la respuesta cabe en una revisión narrativa (»¿qué se sabe de la IA en educación?»).
- No comprobar si ya existe una SLR del tema.
- Cambiar criterios de inclusión a mitad de camino sin documentarlo ni justificarlo.
- No decidir desde el principio en qué sede se publicará y qué checklist exige.

CAPÍTULO 5

Fase 2a. Búsqueda: fuentes, cadenas y documentación

La búsqueda debe ser replicable: otro investigador, con tu cadena, tu base de datos y tu fecha, debería obtener (casi) los mismos registros. Solo el 43 % de 311 SLR de ingeniería del software analizadas publican cadenas reutilizables y menos del 5 % reproducen sus resultados (Li, 2021); no seas parte de esa estadística.

5.1 Dónde buscar

Elige fuentes por cobertura temática, tipos de estudio y acceso, y justifica la combinación. Consulta una persona experta en búsquedas si es posible. No existe un número universal de bases suficiente. Índices y plataformas se solapan; conserva la procedencia antes de deduplicar [R+21b].

Fuente	Cobertura y uso
Scopus	Índice multidisciplinar; revistas y congresos
Web of Science	Declara las colecciones consultadas
IEEE Xplore	Ingeniería e informática
ACM Digital Library	Distingue colección a texto completo e índice bibliográfico
SpringerLink / ScienceDirect	Plataformas editoriales; justifica cobertura adicional
ERIC	Educación; texto libre y tesauro
Google Scholar	Complemento; documenta límites y ordenación
dblp	Metadatos de informática; sin resúmenes
OpenAlex / Semantic Scholar	Comprueba cobertura, campos y condiciones de API

Los límites de exportación, campos y sintaxis cambian. Consulta la documentación oficial al buscar y anota fecha, formato, lotes y total exportado. Recuperar texto completo es distinto de identificar registros.

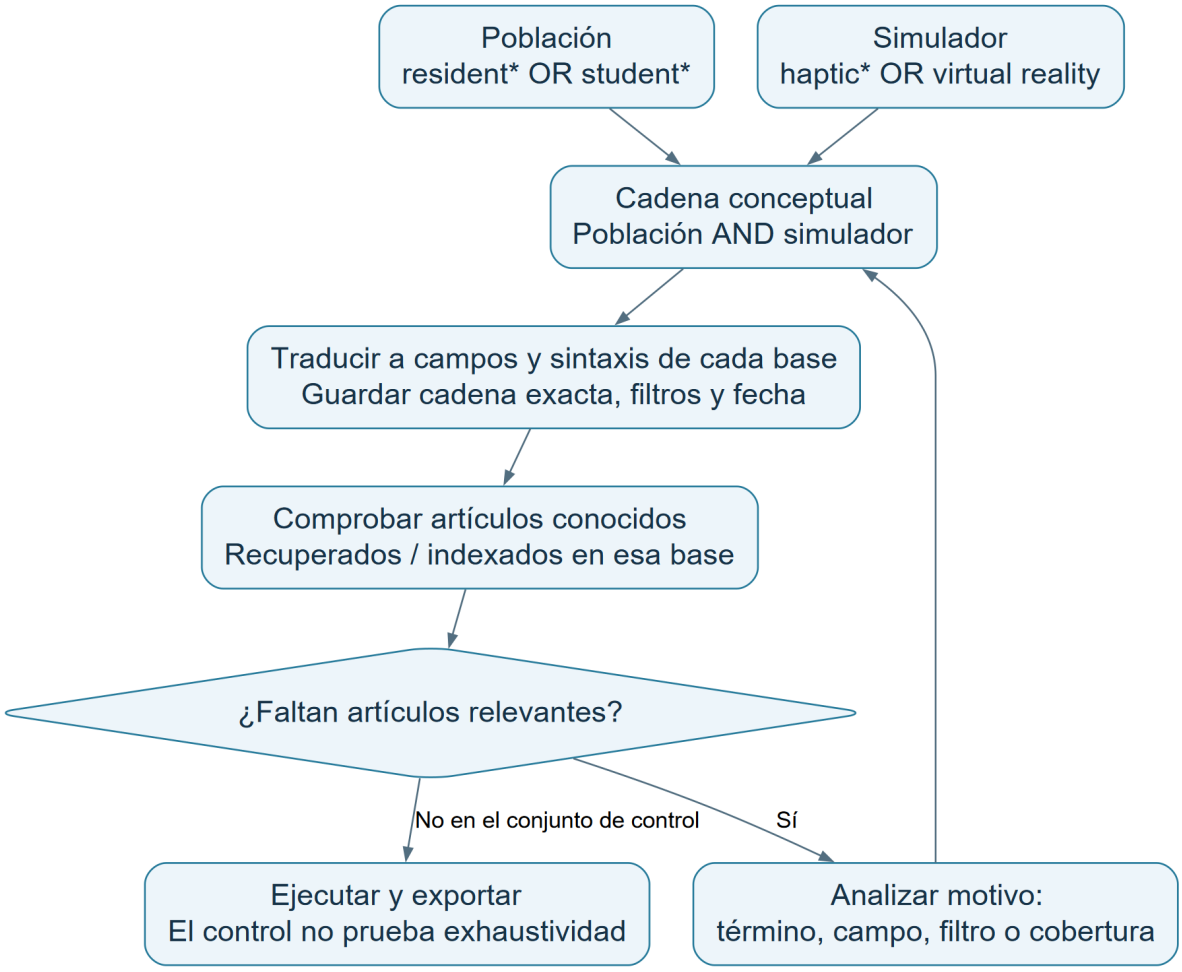


Figura 5.1: Construcción y comprobación de búsqueda. Expresiones conceptuales: adapta sintaxis, campos y truncamiento a cada plataforma. Elaboración propia, CC BY 4.0.

5.2 Construir la cadena de búsqueda

1. **Deriva los conceptos de PICOC**: normalmente población, intervención y resultado; el contexto rara vez entra en la cadena.
2. **Amplía cada concepto con sinónimos**: términos derivados, variantes ortográficas (*modelling*/*modeling*), acrónimos (HCI), términos en otros idiomas si procede, y descriptores del tesauro de la base (MeSH en MEDLINE, tesauro ERIC, IEEE Thesaurus, ACM CCS).
3. **Une sinónimos con OR y conceptos con AND**; evita NOT salvo para excluir un dominio claramente ajeno, porque elimina registros relevantes que mencionen el término de pasada.
4. **Usa paréntesis** para fijar la precedencia y comillas para frases exactas; el truncamiento (*) amplía (*analy** cubre *analysis*, *analyse*, *analytics*).
5. **Prueba la cadena contra un conjunto de control**: 5 a 10 artículos que sabes que deben aparecer. Si falta alguno, revisa los términos.
6. **Adapta la sintaxis a cada base** y guarda la versión exacta.

Ejemplo de Hou et al. (2024), una revisión sistemática sobre el uso de grandes modelos de lenguaje (LLM) en tareas de ingeniería del software, publicada en *ACM Transactions on Software Engineering and Methodology* con todos sus materiales en abierto. La cadena combina dos conceptos, cada uno con una lista larga de sinónimos unida por OR:

```
Concepto 1 (tareas de ingeniería del software):
  "Software Engineering" OR "Software Development" OR Program* OR "Code Generation"
  OR "Code Completion" OR "Code Summarization" OR "Bug Detection" OR "Program Repair"
  OR "Test Generation" OR "Vulnerability Detection" OR ...

Concepto 2 (modelos de lenguaje):
  LLM OR "Large Language Model*" OR "Language Model*" OR LM OR PLM OR Pretrained
  OR "Pre-trained" OR GPT OR ChatGPT OR Codex OR BERT OR CodeBERT OR T5 OR LLaMA OR ..
 ↪.

Cadena final:  (Concepto 1) AND (Concepto 2)
```

La búsqueda se lanzó en siete fuentes (IEEE Xplore, ACM Digital Library, ScienceDirect, Web of Science, SpringerLink, arXiv y dblp), limitada a enero de 2017–enero de 2024, y devolvió más de 218.000 registros, que las fases de cribado redujeron a 395 estudios incluidos. Tres prácticas de esa revisión merecen copiarse: antes de la búsqueda automática hicieron una búsqueda manual en seis sedes de referencia (ICSE, FSE, ASE, ISSTA, TOSEM y TSE) y construyeron con ella un conjunto de control de 51 artículos (*quasi-gold standard*) para validar la cadena; incluyeron arXiv y dblp como fuentes complementarias a las bibliotecas tradicionales; y publicaron las cadenas adaptadas a cada base, las listas de artículos y las decisiones de cribado en un repositorio público, de modo que cualquiera puede replicar la búsqueda.

Las cadenas de cada base deben ser iguales o equivalentes; si no, los resultados no son comparables. El ejemplo de Ferreras-Fernández et al. (2016) muestra una buena práctica adicional: registrar en una tabla cada consulta numerada (#1, #2…), el campo (título, tema), los filtros (años, idiomas) y el número de resultados, y combinarlas al final (#1 OR #2 OR #3 OR #4).

5.3 Snowballing

Las guías de Wohlin (2014) proponen partir de un conjunto inicial heterogéneo (distintos autores, años y sedes) y revisar las listas de referencias (*backward*) y las citas recibidas (*forward*, con Google Scholar o Scopus) hasta que una iteración no aporte artículos nuevos. Wohlin et al. (2022) muestran que la estrategia híbrida Scopus + *snowballing* encuentra en torno a un 30 % más de artículos relevantes que la búsqueda en bases de datos sola. En el diagrama PRISMA estos artículos van en el brazo «otros métodos».

5.4 Literatura gris

En temas donde la práctica profesional va por delante de la academia (DevOps, LLM en programación, herramientas educativas comerciales), una revisión multivocal añade blogs técnicos, informes y documentación. Garousi et al. (2019) dan criterios para decidir si incluirla y cómo evaluar su calidad (autoría, fecha, metodología, citas). Documenta las búsquedas en Google con fecha, número de páginas revisadas y criterio de parada.

5.5 Qué documentar (PRISMA-S)

Para cada fuente: nombre y plataforma (Scopus vía Elsevier), cadena completa tal como se ejecutó, campos, filtros y límites (años, idioma, tipo de documento), fecha de ejecución, número de registros devueltos y método de deduplicación con el número de duplicados eliminados. Si actualizas la búsqueda antes de enviar el artículo, documenta ambas ejecuciones. Guárdalo todo en el material suplementario (Zenodo u OSF).

5.6 Errores frecuentes

Errores frecuentes

- Una cadena distinta por base sin tabla de equivalencias.
- Reportar «se buscó en Google Scholar» sin fecha, sin número de resultados revisados ni criterio de parada.
- No guardar la exportación original (RIS/BibTeX) de cada base.
- Olvidar las actas de congresos en áreas donde son la sede principal (ingeniería del software, HCI).
- Limitar por fecha o idioma sin justificarlo en el protocolo.

5.7 Validación y registro operativo

No todos los componentes de PICOC tienen que convertirse en bloques AND. Añadir resultados o métricas poco descritos en resúmenes puede perder estudios relevantes. Prueba variantes, inspecciona qué añade o elimina cada bloque y conserva el historial. La figura usa dos bloques conceptuales; no es una consulta lista para todas las plataformas.

En cada base, el denominador del control es el número de artículos conocidos que están indexados y cumplen los límites allí. Recuperarlos todos no demuestra exhaustividad. Registra por qué falta cada uno y evita ajustar solo a sus palabras. Publica la consulta íntegra sin «…»: la cadena abreviada de Hou es ilustrativa, no reproducible.

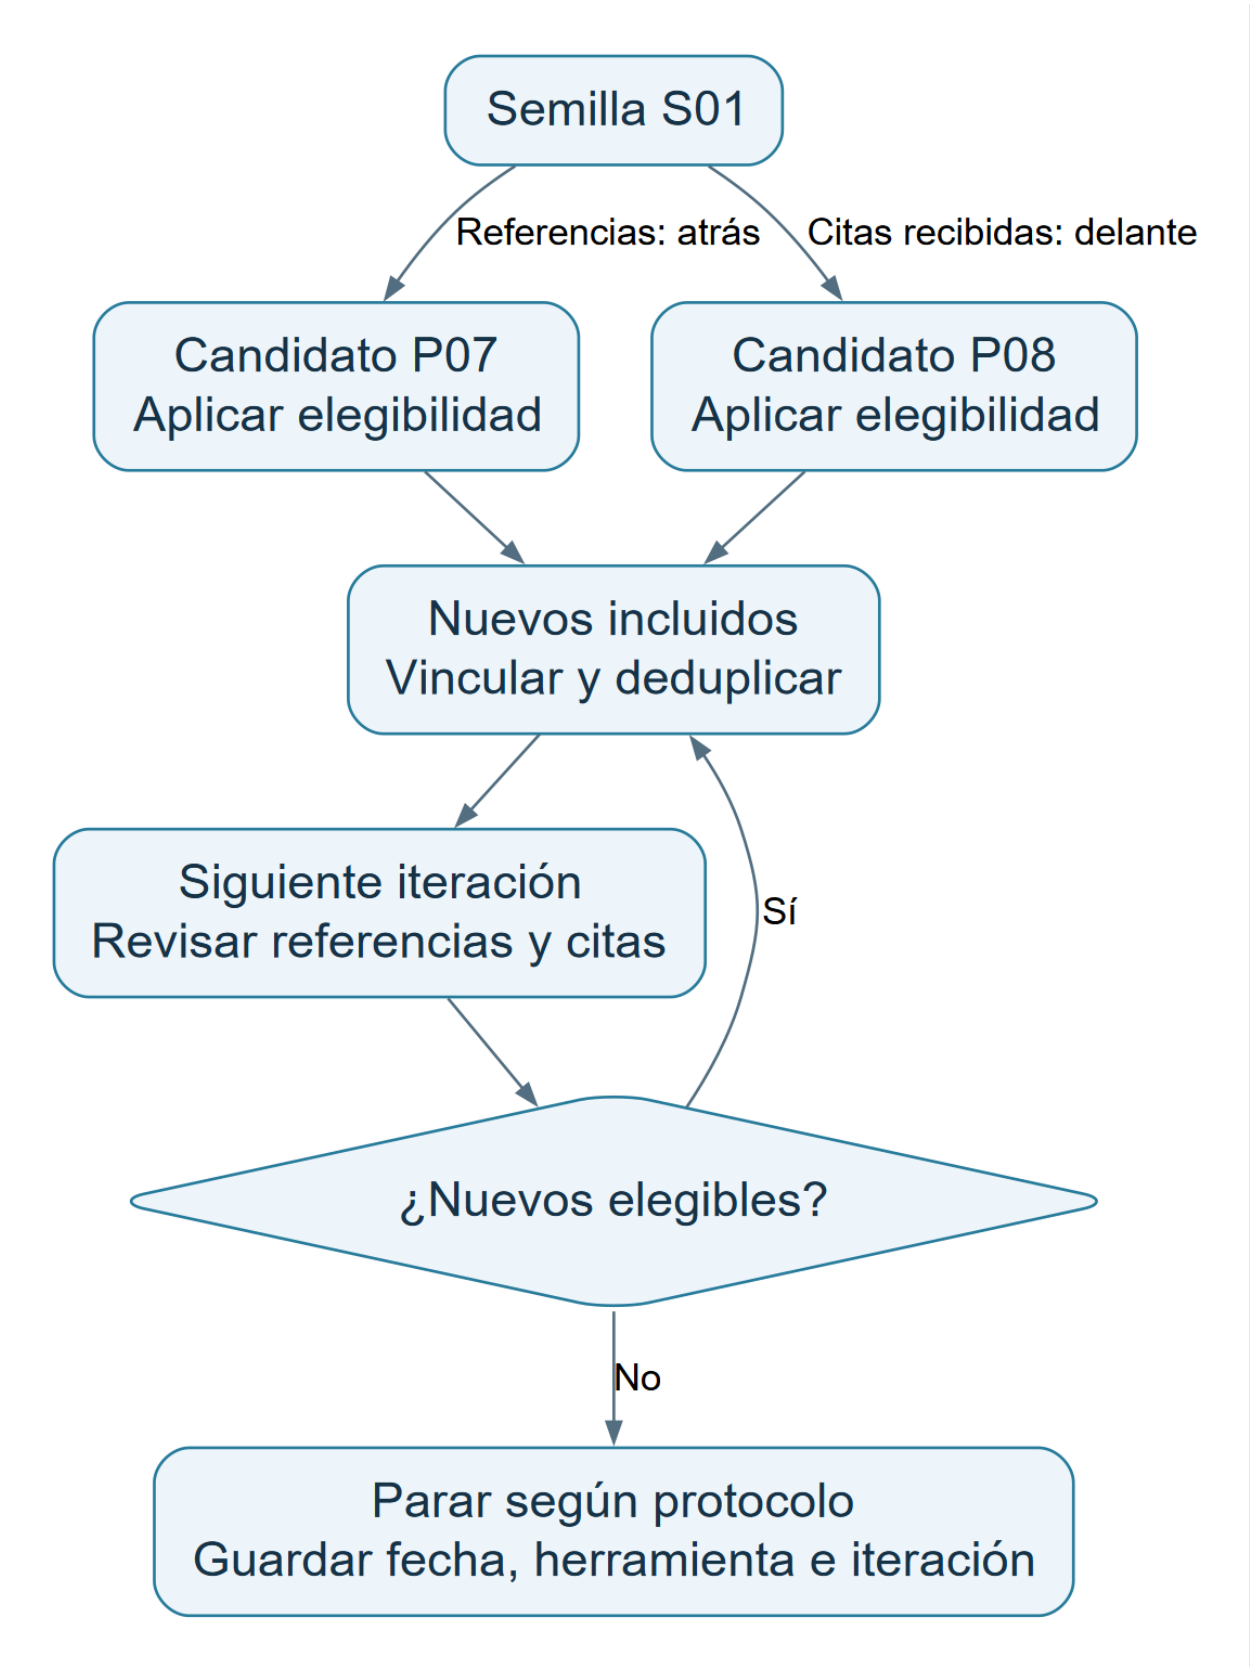


Figura 5.2: Búsqueda por citas e iteraciones. Las flechas son pasos de descubrimiento, no la dirección de las citas. Ejemplo conceptual independiente del dataset. Elaboración propia, CC BY 4.0.

CAPÍTULO 6

Fase 2b. Selección de estudios y evaluación de la calidad

La selección convierte cientos o miles de registros en las decenas de estudios primarios que responderán a tus preguntas. Se hace en fases, con criterios fijados en el protocolo y, siempre que sea posible, con más de un revisor.

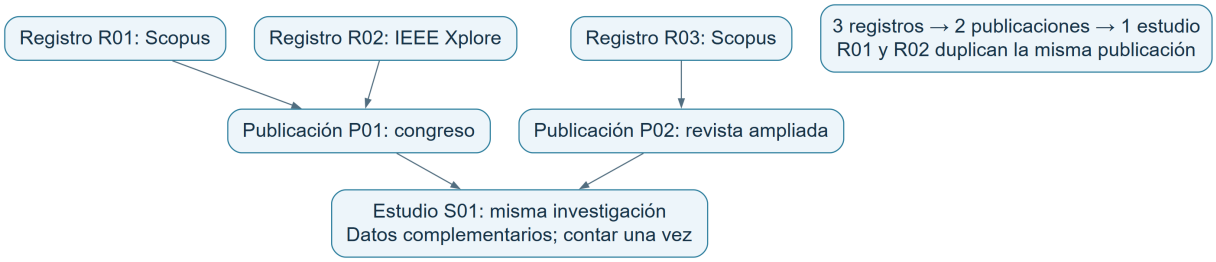


Figura 6.1: Registros, publicaciones y estudios: ejemplo conceptual independiente del dataset, basado en las definiciones PRISMA 2020. Deduplicar y vincular publicaciones son operaciones distintas. Elaboración propia, CC BY 4.0.

6.1 Criterios de inclusión y exclusión

Se definen a partir de las preguntas de investigación, más unos criterios genéricos (idioma, fecha, tipo de documento, revisión por pares). Deben ser claros e inequívocos, y cualquier cambio posterior hay que justificarlo y documentarlo; evita cambios guiados por los hallazgos; si una modificación es necesaria, documenta motivo, momento e impacto. Los criterios de inclusión se encadenan con AND y los de exclusión con OR: basta un criterio de exclusión para descartar.

Ejemplo (Hou et al., 2024, revisión sobre LLM en ingeniería del software): IC1 el artículo declara que usa un LLM **y** IC2 el estudio aborda una tarea de ingeniería del software **y** IC3 el texto completo es accesible. Criterios de exclusión: EC1 artículos cortos (menos de 8 páginas) **o** EC2 duplicados o versiones distintas del mismo estudio de los mismos autores **o** EC3 libros, tesis, monografías, *keynotes*, paneles o sedes sin revisión por pares completa **o** EC4 demostraciones de herramientas y editoriales **o** EC5 artículos de taller o simposio doctoral **o** EC6 literatura gris (informes técnicos) **o** EC7 no escrito en inglés **o** EC8 menciona LLM sin describir la técnica empleada **o** EC9 usa métodos de ingeniería del

software para mejorar los LLM en lugar de LLM para tareas de ingeniería del software. Obsérvese que los tres últimos no son genéricos sino específicos del tema: son los que de verdad separan el estudio relevante del que solo roza el tema. Con esos criterios, más de 218.000 registros se redujeron a 810 tras cribar título y resumen, a 594 tras el texto completo y a 382 tras la evaluación de calidad; el *snowballing* añadió 13, para un total de 395.

Criterios genéricos habituales: fecha (justificada: la aparición de una tecnología, una revisión previa), idioma, tipo de publicación (se suelen excluir editoriales, resúmenes extendidos, pósteres y capítulos sin revisión), población o contexto (nivel educativo, tipo de organización), diseño del estudio (solo empíricos, solo con evaluación) y acceso al texto completo. Vincula las publicaciones del mismo estudio: pueden aportar datos complementarios. Define qué fuente usarás para cada resultado y evita contar dos veces participantes o efectos. Un texto no recuperado se registra como tal en PRISMA, diferenciado de una exclusión por elegibilidad.

6.2 Las fases de cribado

1. **Ejecutar las consultas** y exportar los registros de cada base (RIS o BibTeX), anotando la fecha.
2. **Eliminar duplicados** con el gestor bibliográfico o una herramienta específica; guarda el número eliminado.
3. **Cribar por título y resumen** aplicando los criterios. En caso de duda, pasa el artículo a la siguiente fase; aquí es mejor ser inclusivo.
4. **Cribar a texto completo**, registrando el motivo de exclusión de cada artículo descartado (PRISMA exige listarlos con sus razones).
5. **Añadir los artículos del *snowballing*** y repetir el cribado sobre ellos hasta que no aparezcan nuevos.

El número de fases depende del volumen de candidatos y del número de revisores. Las tasas de exclusión varían mucho: estima el esfuerzo mediante un pilotaje de tu propio corpus.500 registros a 1.700 tras duplicados, a unos 50 tras título y resumen, y a unos 13 tras texto completo; planifica el tiempo en consecuencia. Antes de cribar en serio, calibra: los revisores cribarán de forma independiente una muestra de 50 a 100 registros, compararán sus decisiones y afinarán la interpretación de los criterios.

6.3 Acuerdo entre revisores

El cribado independiente por dos personas reduce errores; los desacuerdos se resuelven por consenso o una tercera persona. Si solo puedes duplicar una parte, justifica el tamaño y selección de la muestra, cubre las decisiones difíciles y declara la limitación. **El 20 % es un ejemplo de planificación, no un mínimo validado ni una garantía de ausencia de sesgo.** Amplía o repite la calibración si cambian los criterios o aparecen discrepancias relevantes.

Informa el número de registros evaluados por ambos, la tabla de decisiones antes del consenso, el acuerdo bruto y, si procede, kappa con su incertidumbre. Las etiquetas habituales de kappa son orientativas; dependen de prevalencia y márgenes. Una muestra con casi todo excluido puede mostrar gran acuerdo y aun así ocultar errores en estudios relevantes.

El test-retest permite comprobar consistencia del mismo revisor, pero no sustituye una segunda evaluación independiente. Un LLM es una herramienta automatizada y debe describirse y validarse como tal, aunque aporte una segunda propuesta de decisión.

6.4 Evaluación crítica: calidad, riesgo de sesgo y certeza

Son conceptos relacionados que responden a preguntas diferentes:

- **Calidad metodológica:** adecuación y transparencia del diseño, ejecución y análisis de un estudio.
- **Riesgo de sesgo:** posibilidad de que sus métodos distorsionen sistemáticamente un resultado.
- **Certeza de la evidencia:** confianza en una conclusión del conjunto de estudios para un resultado concreto. GRADE considera riesgo de sesgo, inconsistencia, imprecisión, indirectitud y sesgo de publicación [SBA+23].

Elige el instrumento según los diseños incluidos y sigue su manual. No todas las herramientas permiten sumar puntos: **MMAT desaconseja una puntuación global**, y AMSTAR 2 utiliza debilidades críticas, no una suma simple [HPF+18, SRW+17]. Conserva cada juicio por dominio, su justificación y la página o fragmento de apoyo.

Instrumento	Para qué tipo de estudio	Notas
Dybå & Dingsøyr (2008)	Estudios empíricos de ingeniería del software	11 criterios sí/no: ¿es investigación y no *lessons learned*?, objetivos, contexto, diseño, reclutamiento, grupo de control, recogida de datos, análisis, reflexividad, hallazgos, valor. La más usada en ingeniería del software
Kitchenham & Charters (2007), apéndice	Cualquier estudio empírico de SE	Preguntas por tipo de diseño (experimento, caso, encuesta)
CASP	Cualitativos, ensayos, cohortes, revisiones	Gratuitas; origen en salud, adaptables
MMAT 2018	Estudios cualitativos, cuantitativos y mixtos	Cinco categorías, cinco criterios cada una; útil en educación
AMSTAR 2	Para evaluar revisiones sistemáticas (estudios terciarios)	16 ítems; valoración global alta, moderada, baja o críticamente baja
ROBIS	Riesgo de sesgo de revisiones sistemáticas	Cuatro dominios: elegibilidad, identificación y selección, recogida de datos, síntesis

RoB 2 se dirige a resultados de ensayos aleatorizados; GRADE corresponde al conjunto de evidencia por resultado. Ninguno debe aplicarse automáticamente a cualquier estudio de informática.

Los criterios de Hou et al. (2024) ilustran decisiones de una revisión publicada, no un instrumento universal recomendado. En particular, el prestigio de la sede no sustituye la evaluación metodológica. Justifica cualquier adaptación y cualquier exclusión por evaluación crítica de antemano. No conviertas una suma de calidad en pesos estadísticos: en un metaanálisis los pesos dependen del modelo y de la precisión de las estimaciones.

Explica cómo afecta la evaluación a la síntesis: señalar limitaciones, comparar conclusiones al retirar estudios con problemas importantes o moderar la confianza en los hallazgos. En mapeos descriptivos puede omitirse con justificación; si se extraen conclusiones sobre efectividad, la evaluación crítica resulta necesaria.

Dos personas deben contrastar los juicios y resolver discrepancias. El test-retest mide consistencia de una persona y no equivale a una evaluación independiente.

6.5 Errores frecuentes

Errores frecuentes

- Cribar por título y resumen siendo demasiado estricto, y perder estudios que el resumen describe mal.
- No anotar el motivo de exclusión a texto completo.
- No medir el acuerdo entre revisores, o medirlo y no informarlo.
- Usar la sede de publicación o el número de citas como sustituto de la calidad.
- Inventar una lista de calidad propia cuando existe una validada.

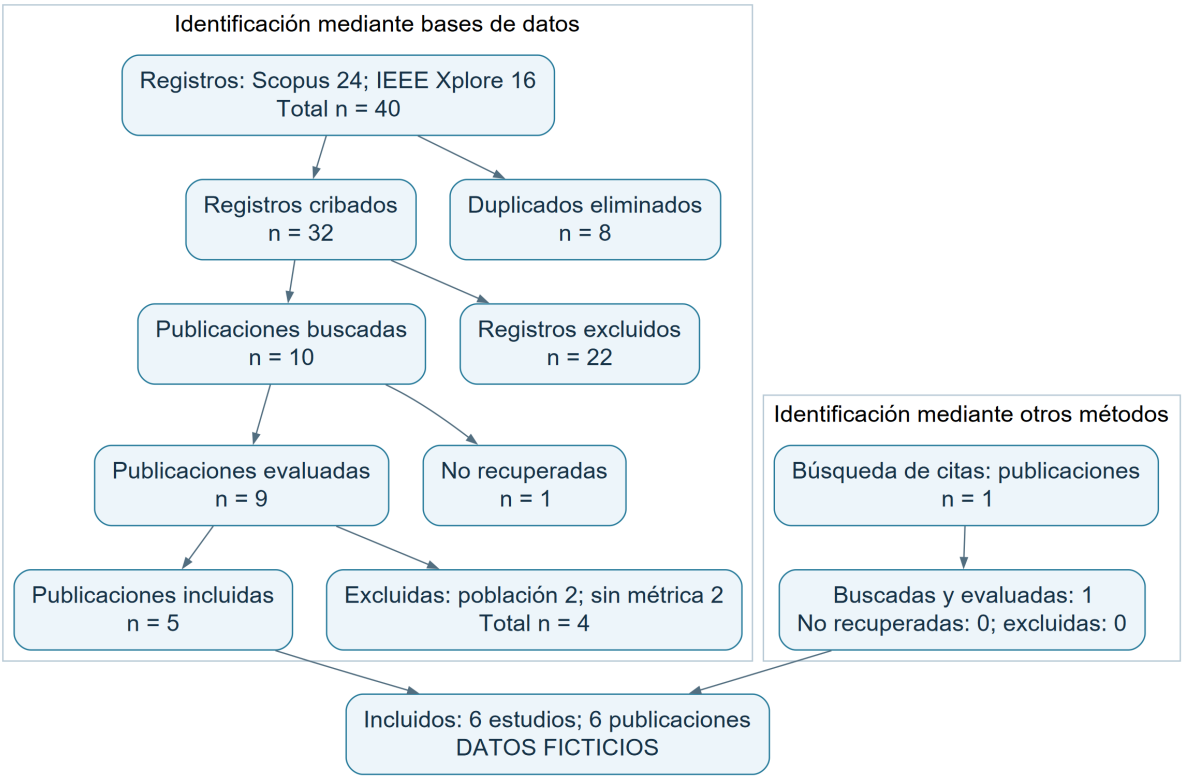


Figura 6.2: Flujo docente adaptado de PRISMA 2020 (Page et al., 2021), CC BY 4.0. Datos ficticios: 40 − 8 = 32; 32 − 22 = 10; 10 − 1 = 9; 9 − 4 = 5; 5 + 1 = 6. No son resultados de la revisión original.

Para una revisión real, usa la plantilla oficial PRISMA 2020 apropiada para revisión nueva o actualizada y las fuentes utilizadas. Este ejemplo es una adaptación docente, no una plantilla oficial sin modificar. Cuenta registros en identificación/cribado, publicaciones en recuperación/elegibilidad y estudios al final [PMB+21]. Los datos están en el *caso práctico*.

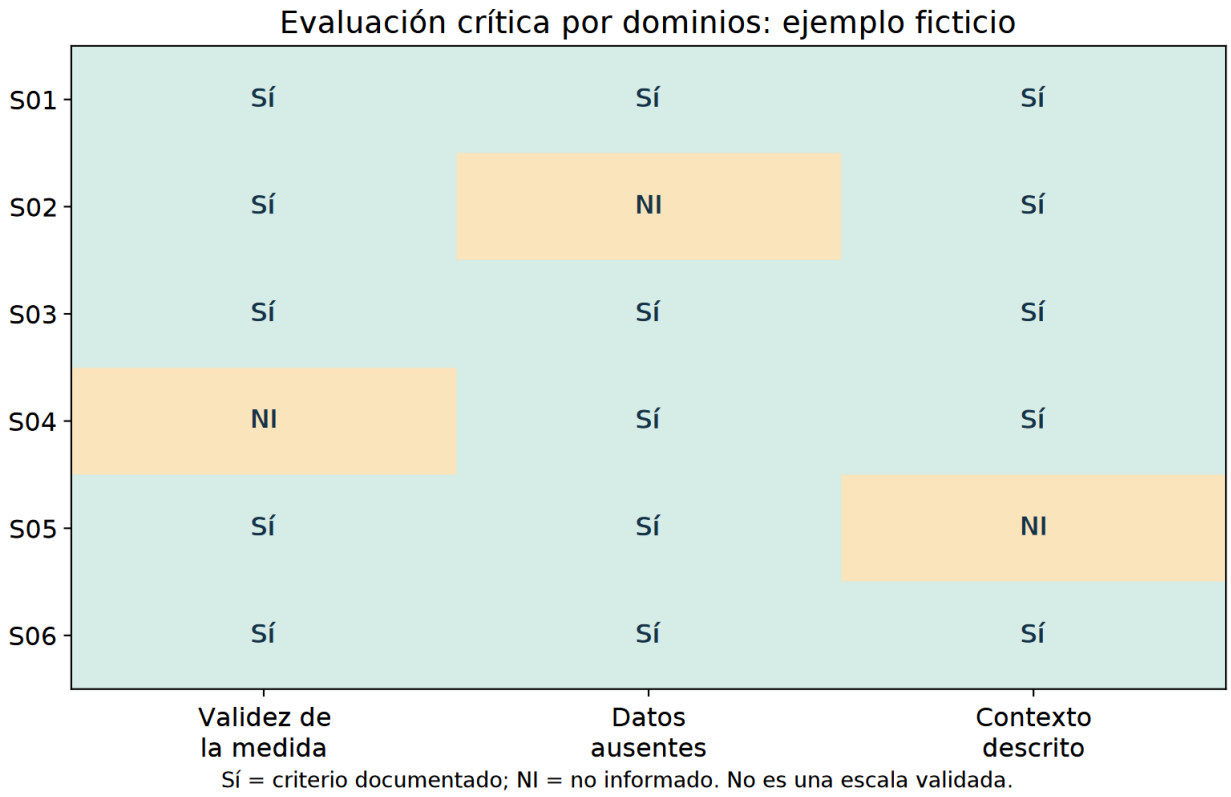


Figura 6.3: Juicios por dominio del ejercicio ficticio. NI significa no informado, no riesgo bajo. Los dominios son didácticos, no una escala validada, y no se suman. Elaboración propia, CC BY 4.0.

CAPÍTULO 7

Fase 2c. Extracción de datos y síntesis

La extracción debe ser homogénea: un formulario con los mismos campos para todos los estudios, definido en el protocolo y pilotado con tres o cuatro artículos antes de usarlo en serio. Cada campo debe servir para responder a una pregunta de investigación concreta; si no responde a ninguna, sobra.

7.1 El formulario de extracción

Tiene dos bloques: datos genéricos (identificador único, referencia completa, año, sede y tipo de publicación, país o afiliación, tipo de estudio, contexto, número de participantes) y datos relativos a las preguntas (en el caso práctico de esta guía sobre simuladores hápticos en cirugía: métricas usadas, nivel de experiencia de los residentes, número de participantes). Añade siempre un campo de notas libres, los juicios de evaluación crítica y quién extrajo los datos. Lo más práctico es una hoja de cálculo compartida (Google Sheets, Excel) con una fila por estudio y una columna por campo, o la ficha de extracción de Parsifal.

Para campos categóricos (tipo de contribución, método de evaluación, dominio) define el esquema de clasificación antes de extraer, con valores cerrados. En mapeos sistemáticos Petersen et al. (2008) proponen construir el esquema por *keywording*: leer los resúmenes de los estudios incluidos, anotar conceptos clave y agruparlos en categorías antes de clasificar. Esquemas reutilizables: tipo de investigación de Wieringa et al. (2006) (validación, evaluación, propuesta de solución, filosófico, opinión, experiencia) y tipo de contribución (método, herramienta, modelo, métrica, proceso).

Valida la extracción como el cribado: una segunda persona verifica los datos o realiza extracción independiente, con un plan de muestreo justificado si procede. El test-retest solo comprueba consistencia individual. Durante la lectura completa puede descubrirse que un estudio no es relevante; se excluye y se anota el motivo (Phelps & Campbell, 2012).

7.2 Trazabilidad

Debes poder explicar qué pasó con cada artículo en cada fase y con qué criterio se excluyó. Sin esa trazabilidad ni el revisor del artículo ni el director de la tesis pueden confiar en la revisión. La mayor parte de esa información no cabe en el artículo, así que va a un material suplementario: una hoja de cálculo con todos los candidatos y su decisión por fase, las cadenas de búsqueda, el formulario de extracción completo y la lista de control de calidad. Depósitalo en Zenodo u OSF con DOI y cítalo desde el artículo; es lo que piden PRISMA 2020 (ítem 27) y los Empirical Standards.

7.3 Síntesis

La síntesis responde a cada pregunta a partir de los datos extraídos. Conviene seguir cuatro pasos: presentar los datos del proceso de búsqueda y selección (diagrama PRISMA), tabular los datos de los estudios incluidos, representar gráficamente los datos más característicos y esbozar la respuesta a cada pregunta.

Método	Cuándo	Cómo
Síntesis descriptiva y tabular	Siempre; base de cualquier mapeo	Tablas de estudios por categoría; recuentos y porcentajes; una tabla por pregunta
Síntesis narrativa	SLR con estudios heterogéneos	Agrupar hallazgos por tema o pregunta y describirlos con referencia a los estudios que los sustentan; explicitar contradicciones
Síntesis temática o codificación	Estudios cualitativos o mixtos	Codificar fragmentos, agrupar códigos en temas (Cruzes & Dybå, 2011, para ingeniería del software)
Meta-análisis	Estudios cuantitativos con la misma variable y diseños comparables	Tamaños del efecto combinados con modelo de efectos aleatorios; heterogeneidad (I^2); gráficos de bosque. Evita el *vote counting*
Mapeo y visualización	Mapeos sistemáticos	Gráficos de tendencia por año, distribución por sede, *bubble plots* que cruzan dos categorías, diagramas Sankey de fuente a decisión

7.4 Representar los datos

Las figuras más útiles (Hou et al., 2024, usan varias de ellas sobre 395 estudios: distribución por sede y por año, evolución anual de los tipos de arquitectura de modelo, recuentos de estrategias de datos y de técnicas de *prompting*, y una tabla de tareas de ingeniería del software por actividad):

- **Gráfico de tendencia**: número de estudios por año, opcionalmente por fuente; muestra si el tema crece o decae.
- **Tabla de autores y de sedes** con su número de publicaciones si responde a una pregunta explícita; los indicadores de la sede no miden la calidad del estudio; responde a «quién» y «dónde».
- **Tabla cruzada estudio × categoría** (una X por celda) para cada pregunta; es la forma más compacta de mostrar qué estudio aporta qué.
- **Gráfico de burbujas** (Petersen et al., 2008; Kitchenham et al., 2015): dos tablas bidireccionales que comparten un eje nominal, con el tamaño de la burbuja igual al número de estudios; es la figura característica de un mapeo.
- **Diagrama Sankey** de fuentes a decisión de inclusión (SankeyMATIC) y **gráficos de anillos** por fuente y año para mostrar el proceso.
- **Diagrama de flujo PRISMA 2020** con el número de registros en cada paso.

Usa la misma paleta y el mismo orden de categorías en todas las figuras, y evita duplicaciones sin propósito; una tabla de datos y una figura pueden coexistir si facilitan comprobación y comprensión, respectivamente.

7.5 Errores frecuentes

Errores frecuentes

- Extraer sin formulario y «ordenar» después.
- Columnas que no responden a ninguna pregunta.
- Presentar la síntesis como una lista artículo a artículo (la «lista de la compra» de los Empirical Standards) en lugar de por tema o pregunta.
- Contar votos («7 estudios a favor, 3 en contra») como si fuera un meta-análisis.
- Gráficos que repiten la tabla sin añadir lectura.

7.6 De los datos a una respuesta argumentada

1. Agrupa por pregunta y contexto, distinguiendo lo observado de la interpretación del autor.
2. Codifica cada fragmento con estudio, publicación y página; define categorías en un diccionario y documenta sus revisiones.
3. Contrasta convergencias, contradicciones, diseños y limitaciones. «No informado» no equivale a «no existe» ni a cero.
4. Redacta una conclusión delimitada, con identificadores de los estudios que la sustentan y las condiciones donde podría cambiar.

En el *ejemplo reproducible*, S01 registra tiempo y errores y S02 solo tiempo. El código «eficiencia temporal» agrupa el tiempo; «seguridad de ejecución» agrupa errores y fuerza. Esta clasificación no demuestra que el tiempo mida competencia clínica ni que una métrica sea superior. S02 omite el tratamiento de datos ausentes y S04 la validez de la medida: ambas limitaciones deben acompañar la interpretación.

Para resultados cuantitativos, no cuentes estudios significativos frente a no significativos. Considera magnitud, dirección, precisión y compatibilidad de los resultados. Un modelo de efectos aleatorios no resuelve por sí solo diferencias conceptuales o metodológicas incompatibles [Cochrane].

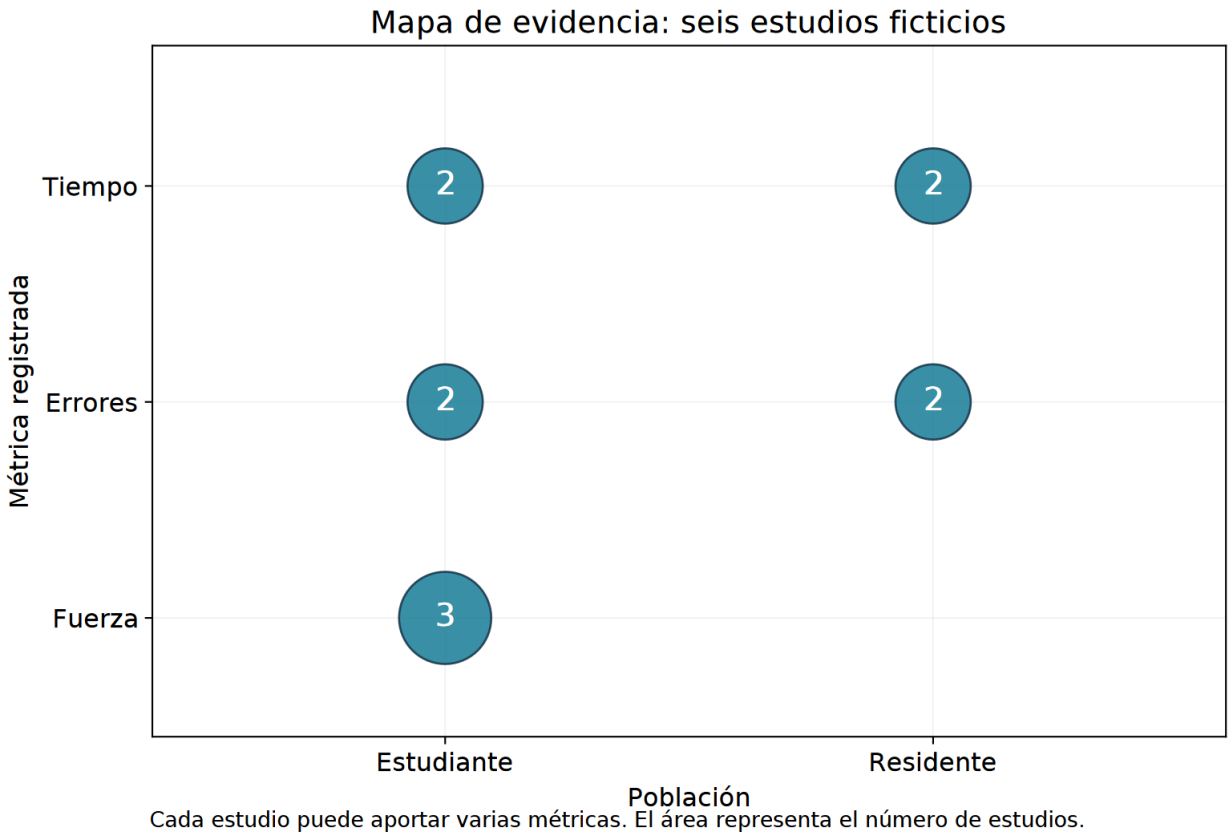


Figura 7.1: Mapa de evidencia del ejercicio ficticio. Área y etiqueta indican estudios; un estudio puede aparecer en varias métricas. Una celda vacía no basta para priorizar investigación. Elaboración propia, CC BY 4.0.

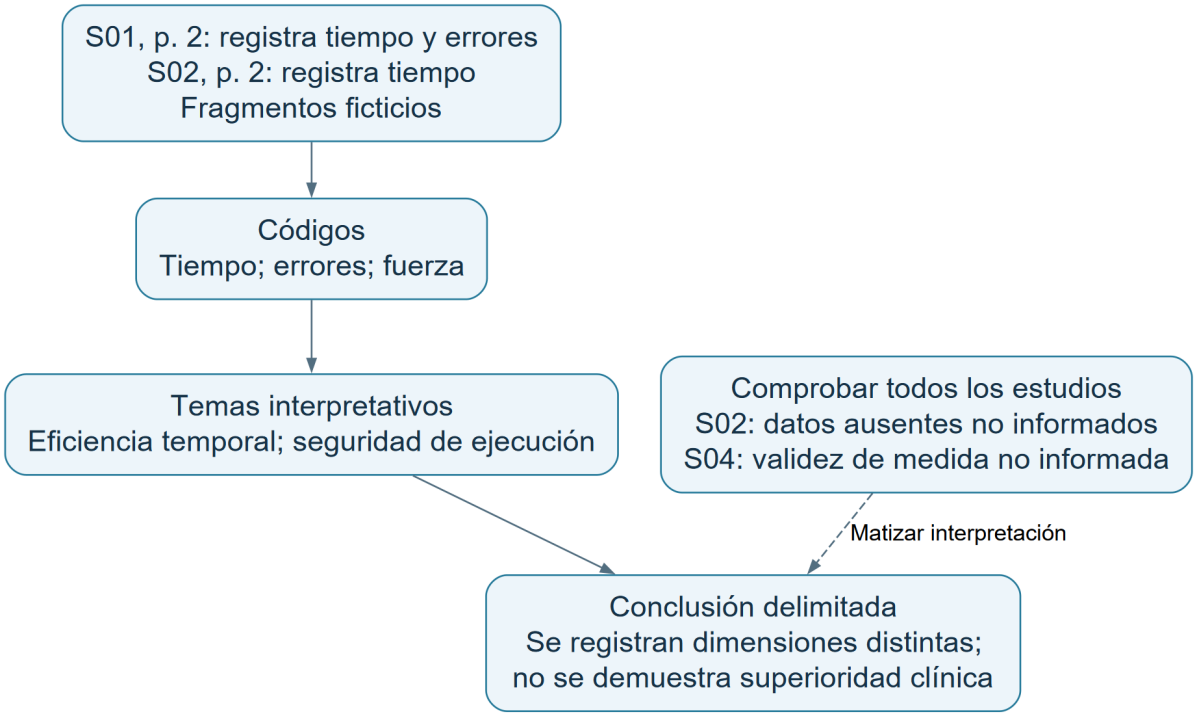


Figura 7.2: Del fragmento al tema y la conclusión. Fragmentos ficticios: los temas son interpretaciones que deben justificarse y contrastarse con todos los estudios. Elaboración propia, CC BY 4.0.

CAPÍTULO 8

Fase 3. Redacción y publicación

El artículo de una SLR tiene una estructura fija y los revisores la buscan: el diagrama de flujo, las cadenas de búsqueda y las limitaciones permiten evaluar su transparencia y rigor. Escribe con el checklist (PRISMA 2020 o SEGRESS) al lado y rellénalo antes de enviar; muchas revistas lo piden como material suplementario.

8.1 Estructura recomendada (Kitchenham et al., 2015; PRISMA 2020)

#	Sección	Contenido
1	Título	Tema y tipo de revisión («revisión sistemática», «mapeo sistemático», «meta-análisis»)
2	Resumen	Estructurado: contexto, objetivos, método (fuentes, fechas, criterios, número de estudios), resultados, conclusiones (PRISMA 2020 for Abstracts, 12 ítems)
3	Introducción	Justificación (qué revisiones existen y por qué hace falta esta), objetivos y preguntas
4	Contexto	Lo necesario para entender el tema y los conceptos clave
5	Método	Dónde está el protocolo; fuentes, cadenas y fechas; criterios de elegibilidad; proceso de selección (cuántos revisores, cómo se resolvieron desacuerdos, herramientas usadas); extracción; evaluación de calidad; método de síntesis. Decide qué va al cuerpo y qué al apéndice
6	Resultados	Diagrama PRISMA con el número de estudios excluidos en cada fase; características de los estudios incluidos; calidad y sesgos; síntesis por pregunta con tablas y figuras
7	Discusión	Respuesta a cada pregunta, implicaciones para investigación y práctica, y limitaciones
8	Conclusiones	Interpretación general y trabajo futuro
9	Agradecimientos y declaraciones	Financiación, conflictos de interés, uso de IA si lo hubo
10	Apéndices y material suplementario	Cadenas por fuente, formulario de extracción, lista de estudios excluidos a texto completo con motivo, lista de control de calidad, datos extraídos

Si has hecho mapeo y SLR, el artículo suele tener una sección de resultados para cada uno; cada sección responde a sus preguntas y usa gráficos, tablas y explicaciones visuales. Las diez reglas de Pautasso (2013) siguen vigentes: define tópico y audiencia, toma notas mientras lees, mantén la revisión centrada pero de interés amplio, sé crítico y consistente, busca una estructura lógica, aprovecha la retroalimentación, incluye tu propia investigación con objetividad y mantente al día sin olvidar los estudios antiguos.

8.2 Limitaciones y amenazas a la validez

Una SLR honesta declara sus amenazas y qué hizo para mitigarlas. Las cuatro clásicas en ingeniería del software (Ampatzoglou et al., 2019) son:

- **Validez de constructo**: ¿los términos de búsqueda y los criterios capturan el concepto estudiado? Mitigación: conjunto de control, sinónimos, pilotaje.
- **Validez interna**: ¿el cribado y la extracción se hicieron sin sesgo? Mitigación: dos revisores, kappa, protocolo registrado.
- **Validez externa**: ¿los resultados se generalizan? Depende de la cobertura de fuentes, idioma y años; el sesgo de publicación de los primarios no se puede eliminar.
- **Fiabilidad**: ¿otro equipo obtendría lo mismo? Mitigación: cadenas, fechas y datos publicados.

SEGRESS pide llamar a esta sección «limitaciones»; el contenido es el mismo.

8.3 Dónde publicar

Busca revisiones recientes de tu tema. Comprueba en las fuentes editoriales alcance, tipos de artículo, instrucciones para revisiones, extensión y políticas de datos e IA. Verifica APC, exenciones y acuerdos institucionales. Distingue SJR y JCR, sus categorías y sus años.

Ejemplos de afinidad temática: Information and Software Technology, Journal of Systems and Software y ACM Computing Surveys para informática; Computers & Education, Educational Research Review y EKS para educación. No son un ranking ni una garantía de aceptación.

Confirma si admiten actualmente tu tipo de revisión y guarda fuente y fecha. Si divides una revisión en varias publicaciones, justifica preguntas diferenciadas, declara el corpus compartido y evita duplicar resultados.

8.4 Qué esperar de la revisión por pares

Los comentarios más habituales a una SLR: la búsqueda no es reproducible; falta una fuente obvia; un solo revisor cribó; no hay evaluación de calidad; la síntesis es una lista; no se discuten las amenazas a la validez; el artículo es demasiado largo. Varios de ellos se anticipan con el checklist; el último, moviendo tablas al material suplementario. Ten en cuenta también que no todos los revisores conocen bien el método: justifica la evaluación crítica elegida y por qué procede o no un metaanálisis.

Parte III

Herramientas e IA

CAPÍTULO 9

Herramientas

Elige según tarea, trazabilidad, acceso institucional, exportación y conservación de datos. Prueba un conjunto pequeño antes de introducir toda la revisión.

Necesidad	Opciones oficiales	Qué comprobar
Referencias y duplicados	Zotero	Revisa fusiones; conserva procedencia
Cribado y protocolo	Rayyan, Parsifal, CADIMA, Covidence	Comprueba roles, independencia, discrepancias y exportación
Aprendizaje activo	ASReview	Valida ordenación, parada y auditoría
Extracción	EPPI-Reviewer, JBI SUMARI	O una hoja de cálculo: campos definidos y página de origen
Descubrimiento por citas	Semantic Scholar, ResearchRabbit, Connected Papers, Litmaps	Registra pasos, cobertura y fecha
IA para apoyo	Elicit, Scite, NotebookLM	Verifica documentos y cada dato extraído
Bibliometría	VOSviewer, bibliometrix	No sustituye la síntesis crítica
Visualización	PRISMA2020	R, Python u hoja de cálculo para otros gráficos

9.1 Aprendizaje activo y criterio de parada

Los ahorros publicados corresponden a datasets y configuraciones concretos; no garantizan recuperación en tu revisión [vdS+21]. Simular sobre datos ya etiquetados no equivale a validar una revisión nueva. Ordenar la lectura y dejar registros sin leer son decisiones diferentes.

Una racha de 50–100 irrelevantes no demuestra que no queden estudios pertinentes. Justifica regla de parada, auditoría y riesgo residual; informa cuántos registros quedaron sin evaluar y cómo se trataron. El volumen por sí solo no determina la necesidad de aprendizaje activo.

9.2 Condiciones que debes verificar

Planes gratuitos, precios, versiones y límites cambian. Consulta los enlaces oficiales y registra fecha, versión o plan, coste y restricciones aplicables. No presupuestes con cifras históricas. Comprueba independencia de decisiones, acceso por roles, privacidad y exportación de discrepancias. Conserva periódicamente copias abiertas de referencias, decisiones, extracción y diccionario de datos. El Systematic Review Toolbox ayuda a localizar alternativas por fase.

CAPÍTULO 10

IA generativa en una SLR: qué puede hacer y cómo declararlo

La IA generativa ya forma parte del flujo de muchas revisiones, pero la evidencia de 2023 a 2026 es clara: los modelos de lenguaje sirven como **apoyo** (segundo revisor, prefiltro, borrador de extracción), no como sustituto del juicio humano. La postura conjunta de Cochrane, Campbell, JBI y CEE de noviembre de 2025 lo resume: los autores siguen siendo responsables de todo, la IA solo se usa si no compromete el rigor, con supervisión humana, y todo uso que haga o sugiera juicios se declara (Flemyng et al., 2025).

10.1 Qué dice la evidencia, fase por fase

Fase	Qué funciona	Qué no, y evidencia
Planificación	Afinar preguntas, proponer sinónimos y términos, revisar el protocolo con PRISMA-P	Nada especialmente arriesgado si revisas lo que propone
Búsqueda	Generar variantes de cadena y traducirlas entre bases (Polyglot); búsqueda preliminar en Elicit o Undermind	Pedir referencias a un chatbot: Chelli et al. (2024) midieron tasas de referencias inventadas del 28,6 % en GPT-4 y del 39,6 % en GPT-3.5 (91,4 % en Bard), con solo un 16 a 20 % de DOI correctos
Cribado por título y resumen	Como apoyo automatizado al cribado con regla «sensible»: Tran et al. (2024) obtienen sensibilidad del 94,6 al 99,8 % perdiendo 0 o 1 de 26 estudios, a costa de una especificidad del 2 al 47 %	Como revisor único: Guo et al. (2024) sobre 24.307 registros obtienen sensibilidad para incluidos de 0,76 (0,59 a 1,0 según revisión). En ingeniería del software, Felizardo et al. (ESEM 2024) obtienen un 75 y un 86 % de aciertos con GPT-4 en dos SLR y concluyen que no es aconsejable externalizar la selección; Thode et al. (IST 2025) alcanzan un *recall* del 98 al 99 % combinando dos modelos, con una precisión del 27 %
Cribado a texto completo	Prometedor con prompts bien diseñados (Khraisha et al., 2024)	Dependiente del prompt y de la versión del modelo; resultados no estables
Extracción de datos	Borrador de la ficha a partir del PDF (Elicit, Covidence, LLM con el PDF) que un humano verifica campo a campo	Fiabilidad «moderada» tras ajustar por azar (Khraisha et al.); números y tablas se transcriben mal con frecuencia
Síntesis y redacción	Resumir tus propias notas, pulir el inglés, proponer estructura	Redactar hallazgos sin haber leído los estudios; inventar citas

Patrón común de todos los estudios: la sensibilidad alta solo se consigue aceptando muchos falsos positivos, los resultados varían con el prompt y la versión del modelo, y en datasets antiguos hay riesgo de que el modelo haya visto las revisiones durante su entrenamiento (Dennstädt et al., 2024). Las versiones de modelo cambian cada pocos meses, así que estas cifras caducan; lo que no caduca es la obligación de validar en tu propio conjunto.

10.2 Protocolo de uso responsable

1. Define tareas, modelo, versión, prompts, parámetros y supervisión antes de su uso; documenta los cambios.
2. Construye un conjunto de referencia evaluado por dos personas y resuelto por consenso. Justifica su tamaño y composición: debe incluir suficientes estudios relevantes, casos dudosos y distintos tipos de documento. Separa el ajuste del prompt de la validación final.
3. Informa verdaderos y falsos positivos y negativos, sensibilidad, especificidad, precisión e intervalos de confianza. **Ni 100–200 registros ni una sensibilidad puntual del 95 % garantizan seguridad.** Si solo hay cinco relevantes y se recuperan todos, la evidencia sobre sensibilidad sigue siendo muy imprecisa.
4. Usa el modelo para priorizar o proponer decisiones; un humano verifica las exclusiones y resuelve desacuerdos. Un LLM no cuenta como segundo revisor humano independiente. Audita también el acuerdo humano–IA, que puede compartir errores.
5. Conserva entradas, salidas, versiones, fechas y decisiones finales; verifica cada dato extraído contra su página de origen. Revalida tras cambios importantes del modelo, prompt o corpus.
6. Respeta licencias y condiciones de tratamiento de los documentos; utiliza las opciones institucionales adecuadas. Declara el uso en Métodos, los materiales y el flujo de selección cuando corresponda.

Una regla de parada basada solo en 50–100 irrelevantes consecutivos no demuestra que se haya recuperado toda la evidencia. El protocolo debe justificar el riesgo de omisiones y el procedimiento de comprobación.

10.3 Guías y estándares

- **RAISE** (*Responsible AI use in Evidence Synthesis*, Cochrane, 2025): tres documentos con recomendaciones por rol, cómo evaluar herramientas y cómo seleccionarlas y usarlas; respaldado por más de 30 organizaciones. El Cochrane AI Methods Group (febrero de 2025) coordina su desarrollo.
- **Guía de reporte de la CEE** (documento vivo): para cada sistema de IA, nombre, versión y desarrollador; justificación y estudios de validación; tareas automatizadas; validación propia o motivo para no hacerla; limitaciones; prompts y código como suplemento; financiación y conflictos. Incluye una plantilla de párrafo de Métodos.
- **PRISMA 2020**: los ítems 8 y 9 (selección y extracción) ya piden indicar las herramientas de automatización usadas. La extensión PRISMA-trAIce (JMIR AI, diciembre de 2025) propone 14 ítems y un diagrama de flujo que separa exclusiones humanas y de IA; es una propuesta sin respaldo formal todavía. No confundir con PRISMA-AI, que es para revisiones de estudios clínicos de IA.
- **Screen4Me** de Cochrane reduce entre el 50 y el 70 % los registros en revisiones de ensayos, pero solo para revisiones Cochrane.

10.4 Qué exigen las editoriales

Editorial	Política
Elsevier (IST, JSS, C&E)	Declaración de IA en una sección propia del manuscrito (herramienta, propósito, supervisión); la IA no puede ser autora; la corrección gramatical básica está exenta; la IA usada en el método se describe en Métodos
IEEE (TSE, TLT, Access)	Divulgar en los agradecimientos el sistema y las secciones afectadas (texto, figuras, código); IEEE Access además exige citarlo en cada sección con texto generado
ACM (CSUR, TOCE)	La IA no puede ser autora; divulgar el uso generativo, normalmente en agradecimientos; correctores y traducción exentos
Springer Nature	Semáforo: pulido de lenguaje (verde), uso evaluativo o redacción (ámbar: verificar y declarar), autoría de IA o citas fabricadas (rojo)

En todas ellas los revisores tienen prohibido subir manuscritos a herramientas públicas. Consulta también el código de integridad y las condiciones de uso de IA de tu universidad; documenta las reglas aplicables en la fecha del trabajo.

Estas políticas son orientativas y cambian: verifica las instrucciones vigentes de la revista al enviar, y registra fuente y fecha. Los porcentajes de validación de la tabla corresponden a los modelos y datasets históricos citados, no al rendimiento actual de cualquier LLM.

10.5 Ejemplo de párrafo de declaración

```
Durante el cribado por título y resumen se utilizó GPT-4o (OpenAI, versión 2026-05,␣
↪vía API) como segundo revisor, con el prompt reproducido en el material␣
↪suplementario S3. En una muestra de 200 registros cribados de forma independiente␣
↪por dos autores, el modelo alcanzó una sensibilidad de 0,97 y una especificidad de␣
↪0,61 (κ = 0,48). Los desacuerdos entre el modelo y el primer revisor (n = 143)␣
↪fueron resueltos por el segundo autor. La IA no intervino en la extracción ni en la␣
↪síntesis. Para el pulido lingüístico del manuscrito se usó DeepL Write; los autores␣
↪revisaron y son responsables de todo el contenido.
```

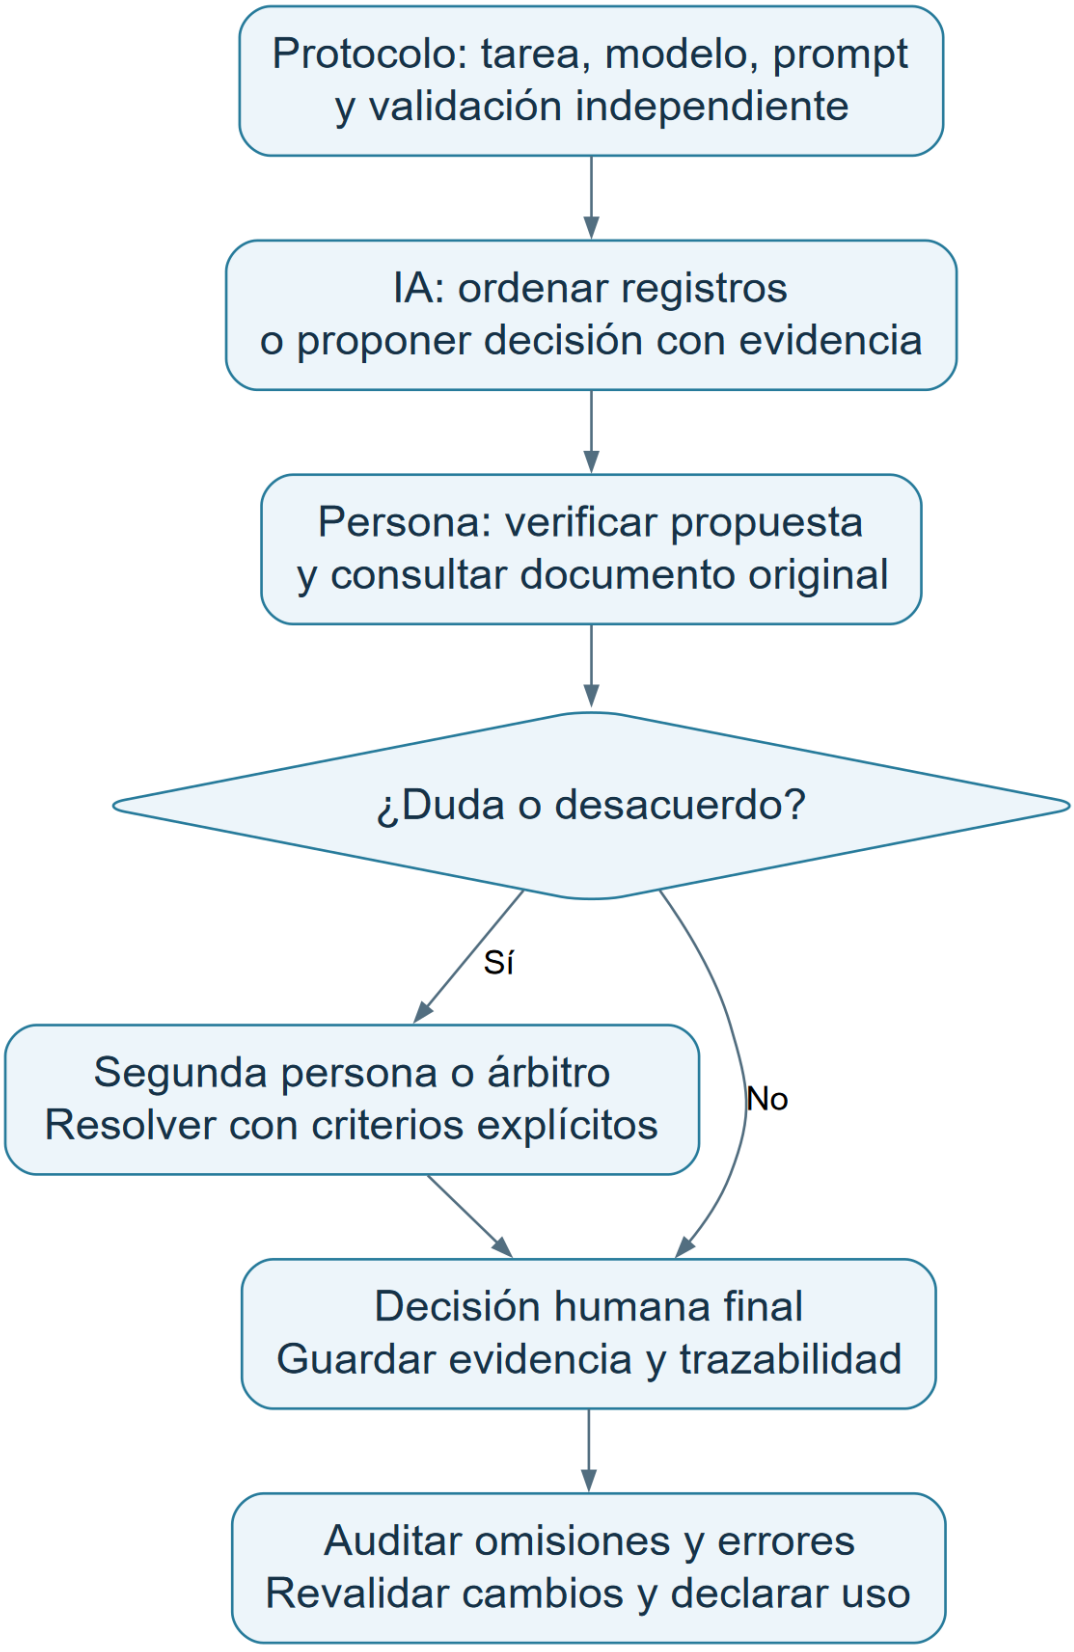


Figura 10.1: Colaboración humano–IA con decisión humana y auditoría. Una propuesta automatizada no sustituye la revisión humana independiente. Elaboración propia, CC BY 4.0.

Parte IV

Práctica

CAPÍTULO 11

Caso práctico guiado

El caso que sigue es una SLR de un solo autor sobre métricas para evaluar el desempeño de residentes de cirugía con simuladores hápticos. Es pequeño (menos de 50 candidatos) y por eso ilustra bien las decisiones y las validaciones que hay que planificar cuando no hay equipo.

11.1 1. Pregunta y PICOC

Pregunta: *En el campo de la cirugía, ¿qué métricas existen para evaluar de forma objetiva el desempeño de un residente utilizando simuladores hápticos?*

Criterio	Valor	Palabras clave
Población / Problema	Evaluación objetiva del desempeño; residente	«objective assessment»; performance; resident
Intervención	Simulador háptico	«haptic simulator»
Comparación	Ninguna	—
Resultado	Métricas	metric
Contexto	Cirugía	surgery

11.2 2. Conjunto de semi-referencia

Antes de buscar, identifica a mano (o preguntando a un experto) un pequeño conjunto de artículos que responden directamente a la pregunta (Zhang, Babar & Tell, 2011, lo llaman *quasi-gold standard*). Servirá para extraer palabras clave de sus títulos y resúmenes y para validar la cadena: un criterio razonable es que la búsqueda automática recupere todos los artículos conocidos pertinentes indexados en cada fuente (el 70 % del ejemplo histórico no es un umbral general) ; analiza cada ausencia y revisa la cadena cuando corresponda.

11.3 3. Fuentes y restricciones

Cinco o seis fuentes que combinen generales y específicas: Web of Science, Scopus, ScienceDirect, IEEE Xplore y ACM DL (las dos últimas, específicas de informática). Restricciones declaradas: búsqueda en título, resumen y palabras clave; solo inglés; solo artículos de revista o congreso. La limitación reconocida (solo fuentes accesibles desde la Universidad de León) se compensa con búsqueda complementaria y literatura gris.

11.4 4. Cadena de búsqueda, iterada

```
Cadena base (WoS, 1 resultado):
("objective assessment" AND performance AND resident) AND "haptic simulator" AND␣
↪metric AND surgery

Cadena ampliada (WoS, 17 resultados):
("objective assessment" AND performance AND resident*) AND ("haptic simulat*" OR
↪"virtual reality") AND metric* AND surg*
```

La primera versión devolvía un solo artículo; truncar (*resident**, *metric**, *surg**) y añadir un sinónimo de la intervención la amplió a 17. Al ampliar entran falsos positivos; al reducir se pierden falsos negativos: el conjunto de semi-referencia es lo que te dice cuándo parar.

11.5 5. Criterios de selección y fases

Inclusión: en inglés; artículo de revista o congreso; define métricas de evaluación; las métricas evalúan el desempeño de un residente o estudiante de últimos cursos con un simulador háptico o virtual. Exclusión: otro tipo de simulador (realidad aumentada, modelos físicos); métricas sobre otros aspectos (realismo, factor humano, distinción novato/experto).

Con un solo revisor y pocos candidatos se planifican dos fases: (1) eliminar duplicados y revisar título y resumen, excluyendo si se cumple al menos un criterio de exclusión y pasando a la siguiente fase en caso de duda; (2) descargar y revisar el texto completo con los mismos criterios. Validación por *test-retest* sobre una muestra aleatoria; si los resultados difieren, se revisan los criterios.

11.6 6. Calidad, extracción y síntesis

Lista de control de Dybå & Dingsøyr (2008) con puntuación Sí = 1, Parcialmente = 0,5, No = 0, más dos preguntas específicas (¿se definen las métricas de forma clara? ¿la población son solo estudiantes o residentes?). Extracción en hoja de cálculo con identificador, referencia, métricas (tipo y descripción), nivel de experiencia del residente (ninguna, estudiante de últimos cursos, residente) y número de participantes. Síntesis con tabla de artículos relevantes, gráfico de tendencia por año y gráfico de burbujas que cruza nivel de experiencia y experiencia previa con simuladores (ejes X) contra tipo de métrica (eje Y).

11.7 Cómo lo harías hoy, con lo que añade esta guía

- Registrar el protocolo en OSF antes de lanzar la búsqueda y citar su DOI.
- Documentar la búsqueda con los 16 ítems de PRISMA-S y añadir *snowballing* hacia atrás y hacia delante desde los incluidos.
- Planificar evaluación humana independiente, justificar el muestreo e informar discrepancias antes del consenso.
- Si un LLM propone decisiones, validarlo con un conjunto independiente y declararlo como automatización.
- Generar el diagrama con la app PRISMA 2020 y rellenar el checklist SEGRESS antes de enviar.
- Depositar hoja de cribado, extracción y cadenas en Zenodo.

11.8 Los errores que más vemos en doctorandos

Los errores que más vemos en doctorandos

1. Empezar por la cadena de búsqueda en lugar de por la pregunta.
2. Elegir un tema para el que ya existe una SLR reciente y no citarla ni justificar la nueva.
3. Usar solo Google Scholar o solo una base.
4. No guardar las exportaciones originales ni la fecha de búsqueda y no poder reconstruir el diagrama PRISMA.
5. Cribar solo, sin ninguna validación, y no mencionarlo como limitación.
6. Confundir mapeo con SLR y que el título prometa lo que el método no entrega.
7. Sintetizar artículo a artículo en lugar de por pregunta.
8. Enviar a una revista que ya no acepta revisiones o cuyo formato no admite la extensión necesaria.
9. Usar IA para cribar o extraer sin validarla ni declararla.
10. Tardar tanto que la búsqueda queda desactualizada; evalúa la actualización según la velocidad del campo y la fecha de envío.

11.9 Ejercicio completo reproducible: datos ficticios

Este ejercicio complementa el caso histórico. **Registros, estudios S01–S06, participantes, fragmentos, páginas y juicios son inventados para docencia. No representan resultados científicos ni reconstruyen la revisión original.**

Protocolo: RQ1 pregunta qué métricas se registran por población. Se incluyen residentes o estudiantes de últimos cursos, simulador háptico/virtual y al menos una métrica de desempeño. EC1: población distinta; EC2: sin métrica. Los revisores ficticios A/B aplican los mismos criterios; su acuerdo no estima el esperable en una revisión real. Los tres dominios de evaluación son ilustrativos, sin puntuación total. No se usa IA.

Selección: Scopus aporta 24 registros e IEEE Xplore 16. Se eliminan ocho duplicados, se criban 32 y se excluyen 22. Se buscan diez publicaciones: una no se recupera y nueve se evalúan. Se excluyen dos por EC1 y dos por EC2. Se incluyen cinco publicaciones de bases y una adicional por citas: seis publicaciones y seis estudios. La rama por citas contiene una publicación buscada, recuperada y elegible. R28 no se recupera: en una revisión real deben registrarse intentos de acceso/contacto; no se etiqueta como exclusión por contenido.

Estudio	Población	Participantes	Métricas (página ficticia 2)
S01	Residente	24	Tiempo; errores
S02	Residente	18	Tiempo
S03	Estudiante	30	Errores; fuerza
S04	Estudiante	16	Tiempo; fuerza
S05	Residente	22	Errores
S06	Estudiante	20	Tiempo; errores; fuerza

Respuesta a RQ1: tiempo y errores aparecen en cuatro estudios cada uno; fuerza, en tres. Los tres estudios de estudiantes registran fuerza; dos registran tiempo y dos errores. Entre residentes, dos registran tiempo y dos errores. Son frecuencias de registro, no comparaciones de eficacia. Una ejecución rápida puede incluir errores: no se demuestra superioridad de una métrica ni se suman participantes como una muestra común.

Evaluación e interpretación: S02 no informa sobre datos ausentes; S04 no informa sobre validez de la medida; S05 describe insuficientemente el contexto. Las demás celdas documentan el criterio. «No informado» exige cautela, no demuestra métodos incorrectos. Conserva estas limitaciones al agrupar tiempo como eficiencia temporal y errores/fuerza como seguridad de ejecución.

Descargas: `Cribado completo` · `Extracción` · `Diccionario` · `Recuentos` · `Paquete completo`.

Reproducción: instala `requirements-figures.txt` en `.venv` y ejecuta `scripts/generate_teaching_assets.py` desde la raíz del repositorio. Comprueba recuentos y crea gráficos desde la extracción descargable. Después ejecuta `scripts/render_diagrams.py` para las fuentes Graphviz. Las columnas e identificadores conservan nombres en inglés por estabilidad; valores y figuras están traducidos.

Comprueba tu comprensión: ¿por qué 11 apariciones de métricas no significan 11 estudios? ¿Por qué R28 no se suma a las cuatro exclusiones? Hay clasificación múltiple y R28 nunca pudo evaluarse.

CAPÍTULO 12

Plantillas y listas de control

Copia estas plantillas a tu propio documento o hoja de cálculo y rellénalas en orden. Están alineadas con PRISMA-P, PRISMA-S y SEGRESS, de modo que al terminar tengas casi todo lo que el checklist de reporte te pedirá.

12.1 Plantilla de protocolo

```
# Protocolo de revisión sistemática: <título>
Versión: 1.0 · Fecha: <aaaa-mm-dd> · Registro: <DOI de OSF/Zenodo>
Autores y roles: <revisor 1, revisor 2, árbitro>

## 1. Justificación
- Revisiones previas localizadas (cadena y fecha de esa búsqueda) y por qué no bastan
- A quién sirve esta revisión y cómo

## 2. Objetivos y preguntas
- Tipo de revisión: SLR / mapeo / scoping / MLR
- PICOC
- MQ1… / RQ1… (cada una con el campo de extracción que la responde)

## 3. Estrategia de búsqueda
- Fuentes (nombre, plataforma, motivo)
- Cadena genérica y adaptación por fuente
- Restricciones: campos, años, idiomas, tipos de documento (justificadas)
- Conjunto de control (lista de artículos) y umbral de recuperación
- Snowballing: hacia atrás / hacia delante, criterio de parada
- Literatura gris: fuentes y criterio de parada

## 4. Criterios de elegibilidad
- Inclusión (IC1…, unidos por AND)
- Exclusión (EC1…, unidos por OR)
```

(continúe en la próxima página)

(proviene de la página anterior)

```
## 5. Proceso de selección
- Fases (duplicados, título/resumen, texto completo)
- Revisores por fase, calibración, resolución de desacuerdos, medida de acuerdo
- Herramientas (gestor, cribado, aprendizaje activo, IA) y cómo se validan

## 6. Evaluación de la calidad / riesgo de sesgo
- Instrumento por diseño, dominios, justificaciones y uso en la síntesis; exclusiones
 ↪y análisis de sensibilidad justificados

## 7. Extracción de datos
- Formulario (campos, valores permitidos), pilotaje, validación

## 8. Síntesis
- Método por pregunta (tabular, narrativa, temática, meta-análisis), figuras previstas

## 9. Reporte y difusión
- Checklist (PRISMA 2020 / SEGRESS), sede prevista, material suplementario

## 10. Cronograma y recursos

## 11. Registro de cambios al protocolo
| Fecha | Cambio | Motivo |
```

12.2 Ficha de extracción (columnas de la hoja de cálculo)

Bloque	Campos
Identificación	ID (S01…), cita completa, DOI, año, sede, tipo (revista, congreso, capítulo), país de la primera afiliación, fuente de la que procede
Diseño	Tipo de investigación (Wieringa: validación, evaluación, propuesta, filosófico, opinión, experiencia), método empírico (experimento, caso, encuesta, cuasi-experimento), contexto (académico, industrial), participantes y número
Contenido	Un campo por pregunta de investigación, con valores cerrados cuando sea posible; tipo de contribución (método, herramienta, modelo, métrica, proceso)
Calidad	Juicio por dominio, justificación, página y efecto en la síntesis
Gestión	Revisor que extrae, fecha, notas, citas textuales relevantes con página

12.3 Hoja de cribado (una fila por registro)

ID de registro, ID de publicación, ID de estudio, fuente, título, año, texto recuperado (sí/no), duplicado (sí/no y de cuál), decisión fase 1 revisor A, decisión fase 1 revisor B, decisión final fase 1, decisión fase 2, criterio de exclusión aplicado, origen (búsqueda / snowballing / gris). Cuenta registros, publicaciones y estudios por separado; enlaza las múltiples publicaciones de un estudio. Registra también intentos de recuperación y motivos de texto no recuperado.

12.4 Checklist de reporte abreviado (PRISMA 2020 + SEGRESS)

- El título dice que es una revisión sistemática o un mapeo
- Resumen estructurado con fuentes, fechas, criterios, número de estudios y conclusión
- Justificación con las revisiones previas citadas
- Preguntas numeradas y PICOC
- Protocolo registrado y enlazado; desviaciones explicadas
- Todas las fuentes con cadena completa, filtros y fecha (PRISMA-S)
- Criterios de inclusión y exclusión explícitos
- Proceso de selección: fases, revisores, acuerdo, herramientas de automatización o IA
- Diagrama de flujo PRISMA 2020 con números en cada paso
- Lista de estudios excluidos a texto completo con motivo (suplemento)
- Instrumento de calidad o riesgo de sesgo y resultados por estudio
- Formulario de extracción y datos extraídos disponibles
- Síntesis por pregunta, con tablas y figuras que no se duplican
- Limitaciones o amenazas a la validez con mitigaciones
- Implicaciones para investigación y práctica
- Financiación, conflictos de interés y declaración de IA
- Materiales en repositorio con DOI

12.5 Cronograma orientativo (SLR de doctorado, 300 a 1.500 candidatos)

Fase	Duración típica	Entregable
Búsqueda preliminar y comprobación de revisiones existentes	2 semanas	Lista de revisiones previas; decisión de seguir
Protocolo y revisión por el director	3 a 4 semanas	Protocolo v1.0 registrado
Búsqueda, exportación y deduplicación	1 a 2 semanas	Biblioteca Zotero; tabla de búsquedas
Cribado título y resumen (con calibración)	2 a 4 semanas	Hoja de cribado; kappa
Texto completo y snowballing	4 a 6 semanas	Lista de incluidos y excluidos con motivo
Calidad y extracción	4 a 8 semanas	Hoja de extracción validada
Síntesis y figuras	3 a 4 semanas	Tablas y figuras por pregunta
Redacción, checklist y envío	4 a 6 semanas	Manuscrito y material suplementario

Total: 6 a 9 meses a tiempo parcial. Decide cuándo actualizar según la velocidad del campo y el tiempo desde la búsqueda; doce meses es una alerta orientativa, no un umbral universal.

12.6 Plantillas descargables

- `Protocolo editable`
- `Cribado vacío`
- `Extracción vacía`
- `Registro de búsquedas`
- `Registro de cambios`
- `Checklist editable`
- `Todas las plantillas y el ejemplo`

Parte V

Referencias

CAPÍTULO 13

Referencias y recursos

13.1 Guías metodológicas

- Kitchenham and Charters [KC07] — PDF
- Kitchenham *et al.* [KBB15] — Editorial
- Kitchenham *et al.* [KMB23] — Checklist
- Petersen *et al.* [PFMM08] — PDF
- Petersen *et al.* [PVK15] — EBSE
- Wohlin [Woh14]
- Garousi *et al.* [GFM19] — arXiv
- Ralph and others [R+21a] — Systematic Reviews standard
- Zhang *et al.* [ZBT11]
- Dybå and Dingsøyr [DD08] — PDF
- Grant and Booth [GB09]
- Mengist *et al.* [MSL20]
- Codina [Cod15] — Web
- Pautasso [Pau13]
- Petticrew and Roberts [PR05]
- Higgins, J. P. T., et al. (eds.). *Cochrane Handbook for Systematic Reviews of Interventions*. Versión actual

13.2 Reporte y registro

- Page *et al.* [PMB+21] — BMJ · Versión en español · Checklist · Diagrama de flujo
- Rethlefsen and others [R+21b] — Artículo
- Tricco and others [T+18] — Web
- Moher and others [M+15] — Web
- Haddaway and others [H+22] — App
- Registros: PROSPERO · OSF Registries · INPLASY · Zenodo
- Huotala *et al.* [HKM25] — arXiv

13.3 IA en revisiones

- Flemyng and others [F+25] — Texto
- RAISE: Responsible AI use in Evidence Synthesis [RAISERAuiESynthesis25] — OSF · Cochrane
- CEE. Artificial intelligence reporting guidance. Web
- Holst and others [H+25] — Artículo
- Guo and others [G+24] — Artículo
- Tran and others [T+24] — Resumen
- Khraisha and others [K+24] — arXiv
- Dennstädt and others [D+24] — PDF
- Felizardo and others [F+24] — Programa
- Huotala and others [H+24] — arXiv
- Thode *et al.* [TIM25] — Resumen
- Chelli and others [C+24] — Artículo
- van de Schoot and others [vdS+21] — Artículo
- Gusenbauer and Haddaway [GH20]
- Li [Li21] — arXiv

13.4 Ejemplos y lecturas en español

- Conde González, M. Á., & Rodríguez Sedano, F. J. *Elaboración de una revisión sistemática de la literatura*. Universidad de León y GRIAL, USAL.
- García-Peñalvo [GP17] — Repositorio
- Hou *et al.* [HZL+24] — arXiv · Materiales
- Ferreras-Fernández *et al.* [FFMRGPMV16]
- Humanante-Ramos *et al.* [HRGPCG17]
- Briz Ponce [BP16] — Handle

- Gisbert and Bonfill [GB04]
- Martín Rodero [MR14] — Handle
- Sáenz [Sae01]
- Boote and Beile [BB05]

13.5 Otros recursos

- Systematic Review Toolbox: catálogo de herramientas por fase.
- EQUATOR Network: todas las extensiones de PRISMA y guías en desarrollo.
- TERA tools (antes SR-Accelerator): Polyglot, Deduplicator, Word Frequency Analyser.
- Cochrane Training: cursos gratuitos de metodología.

13.6 Evaluación crítica y certeza

- Hong *et al.* [HPF+18]
- Shea *et al.* [SRW+17]
- Schunemann *et al.* [SBA+23]

Parte VI

Información

CAPÍTULO 14

Acerca de

Este libro recoge una guía práctica para elaborar una revisión sistemática de la literatura (SLR) o un mapeo sistemático en ingeniería e informática, orientada a doctorandos e investigadores que abordan su primera revisión. Se elaboró como material de apoyo durante el doctorado y recoge los estándares vigentes, un panorama de herramientas y una sección sobre el uso responsable de la IA generativa.

La información de cita está reunida en la página *Cómo citar*.

14.1 Cómo está hecho este libro

Este sitio está escrito en archivos Markdown y se convierte a HTML y PDF usando herramientas del ecosistema TeachBooks, Jupyter Book y MyST Markdown, a partir de la plantilla TeachBook USAL de Álvaro Lozano Murciego y André Filipe Sales Mendes.

Los archivos fuente están en un repositorio público de GitHub:

- https://github.com/danihiglesias/guia-slr

14.2 Sobre el autor

Daniel H. de la Iglesia Universidad de Salamanca

- Correo: danihiglesias@usal.es

CAPÍTULO 15

Créditos y licencias

15.1 Créditos del proyecto

Este libro se ha construido a partir de la plantilla TeachBook USAL (Lozano Murciego y Sales Mendes, 2026, CC BY 4.0) con TeachBooks, sobre el ecosistema de Jupyter Book y MyST Markdown.

TeachBooks aporta documentación, componentes y patrones de trabajo que facilitan crear libros docentes abiertos, interactivos y reproducibles.

15.2 Agradecimientos

Agradecemos al proyecto TeachBooks y a la Delft University of Technology (TU Delft) su trabajo en el desarrollo de herramientas abiertas para libros educativos. La página de créditos del manual de TeachBooks sirve como referencia para reconocer de forma explícita las herramientas, comunidades y apoyos institucionales sobre los que se apoya este material.

TeachBooks, Jupyter Book y MyST Markdown se reconocen aquí como herramientas, documentación y comunidades técnicas sobre las que se apoya el proyecto. No forman parte de la autoría del libro.

15.3 Licencia del libro

Este libro se distribuye bajo licencia Creative Commons Attribution 4.0 International (CC BY 4.0).

Esto permite compartir y adaptar el material, siempre que se reconozca la autoría.

15.4 Recursos externos

Salvo indicación explícita en una página concreta, el contenido de este libro es del autor. Las tablas y ejemplos adaptados de otras fuentes se citan en el texto.

Si en alguna página se reutilizan recursos externos, deberán mencionarse allí mismo con su atribución y licencia correspondiente.

15.5 Código y herramientas

El proyecto hace uso de herramientas y bibliotecas externas, entre ellas:

- TeachBooks
- Jupyter Book
- MyST Markdown

Cada herramienta conserva su propia licencia.

15.6 Figuras y datos de esta edición

Figuras docentes originales y datos ficticios: CC BY 4.0. Fuentes: `diagram_sources/es/`, `diagram_sources/en/` y `scripts/generate_teaching_assets.py`. El flujo PRISMA adapta Page et al. (2021), con cifras inventadas y rotulación reorganizada; las plantillas originales tienen licencia CC BY 4.0. Cada pie identifica autoría o adaptación. La matriz ilustra juicios, no reproduce una herramienta validada.

CAPÍTULO 16

Cómo citar

Si utilizas este material, por favor cítalo de la siguiente manera.

16.1 Cita recomendada (APA 7.ª edición)

de la Iglesia, D. H. (2026). *Guía para elaborar una revisión sistemática de la literatura (SLR)*. Universidad de Salamanca. https://github.com/danihiglesias/guia-slr

16.2 BibTeX

También puedes usar el archivo BibTeX descargable: `citation.bib`.

```
@book{de_la_iglesia_guia_slr_2026,
  author = {de la Iglesia, Daniel H.},
  title = {Guía para elaborar una revisión sistemática de la literatura (SLR)},
  year = {2026},
  publisher = {Universidad de Salamanca},
  url = {https://github.com/danihiglesias/guia-slr}
}
```

Nota

Cuando el libro se deposite en Zenodo, esta página se actualizará con el DOI definitivo.

CAPÍTULO 17

Bibliografía

Esta es la bibliografía unificada del libro, generada desde una única base BibTeX. El capítulo de recursos agrupa las lecturas por tema y enlaza sus fuentes.

[BB05] D. Boote and P. Beile. Scholars before researchers. 2005. Educational Researcher, 34(6), 3–15.

[BP16] L. Briz Ponce. Análisis de la efectividad en las aplicaciones m-health en dispositivos móviles dentro del ámbito de la formación médica. 2016. Tesis, USAL. URL: http://hdl.handle.net/10366/132481.

[C+24] M. Chelli and others. Hallucination rates and reference accuracy of ChatGPT and Bard for systematic reviews. 2024. JMIR, 26, e53164. URL: https://www.jmir.org/2024/1/e53164.

[Cod15] L. Codina. No lo llame Análisis Bibliográfico, llámelo Revisión Sistematizada. 2015. URL: https://www.lluiscodina.com/revision-sistematica-salsa-framework/.

[D+24] F. Dennstädt and others. Title and abstract screening for literature reviews using large language models. 2024. Systematic Reviews, 13, 158. URL: https://boris.unibe.ch/197864/1/s13643-024-02575-4.pdf.

[DD08] T. Dybå and T. Dingsøyr. Empirical studies of agile software development: A systematic review. 2008. Information and Software Technology, 50, 833–859. doi:10.1016/j.infsof.2008.01.006.

[F+24] K. R. Felizardo and others. ChatGPT application in Systematic Literature Reviews in Software Engineering. 2024. ESEM 2024. URL: https://conf.researchr.org/details/esem-2024/esem-2024-technical-track/2/ChatGPT-application-in-Systematic-Literature-Reviews-in-Software-Engineering-an-eval.

[FFMRGPMV16] T. Ferreras-Fernández, H. Martín-Rodero, F. J. García-Peñalvo, and J. A. Merlo-Vega. The Systematic Review of Literature in LIS: An approach. 2016. TEEM'16, 291–298.

[F+25] E. Flemyng and others. Position statement on AI use in evidence synthesis (Cochrane, Campbell, JBI, CEE). 2025. URL: https://www.sei.org/publications/position-statement-on-ai-use-in-evidence-synthesis/.

[GP17] F. J. García-Peñalvo. Revisión sistemática de literatura para artículos. GRIAL. 2017. URL: http://repositorio.grial.eu/handle/grial/756.

[GFM19] V. Garousi, M. Felderer, and M. V. Mäntylä. Guidelines for including grey literature and conducting multivocal literature reviews in software engineering. 2019. Information and Software Technology, 106, 101–121. URL: https://arxiv.org/abs/1707.02553v4.

[GB04] J. Gisbert and X. Bonfill. ¿Cómo realizar, evaluar y utilizar revisiones sistemáticas y metaanálisis? 2004. Gastroenterología y Hepatología, 27(3), 129–149.

[GB09] M. J. Grant and A. Booth. A typology of reviews: an analysis of 14 review types and associated methodologies. 2009. Health Information and Libraries Journal, 26(2), 91–108.

[G+24] E. Guo and others. Automated paper screening for clinical reviews using large language models. 2024. JMIR, 26, e48996. URL: https://www.jmir.org/2024/1/e48996.

[GH20] M. Gusenbauer and N. R. Haddaway. Which academic search systems are suitable for systematic reviews or meta-analyses? 2020. Research Synthesis Methods, 11(2), 181–217.

[H+22] N. R. Haddaway and others. PRISMA2020: An R package and Shiny app. 2022. Campbell Systematic Reviews, 18(2), e1230. URL: https://estech.shinyapps.io/prisma\TU\textbackslash{}_flowdiagram/.

[H+25] A. Holst and others. PRISMA-trAIce. 2025. JMIR AI, 4, e80247. URL: https://ai.jmir.org/2025/1/e80247.

[HPF+18] Quan Nha Hong, Pierre Pluye, Sergi Fabregues, Gillian Bartlett, Felicity Boardman, Margaret Cargo, Pierre Dagenais, Marie-Pierre Gagnon, Frances Griffiths, Belinda Nicolau, Alicia O'Cathain, Marie-Claude Rousseau, and Isabelle Vedel. *Mixed Methods Appraisal Tool (MMAT), version 2018: User guide*. 2018. URL: https://mixedmethodsappraisaltoolpublic.pbworks.com/.

[HZL+24] X. Hou, Y. Zhao, Y. Liu, Z. Yang, K. Wang, L. Li, X. Luo, D. Lo, J. Grundy, and H. Wang. Large Language Models for Software Engineering: A Systematic Literature Review. 2024. ACM Transactions on Software Engineering and Methodology, 33(8), 220. URL: https://arxiv.org/abs/2308.10620.

[HRGPCG17] P. Humanante-Ramos, F. J. García-Peñalvo, and M. Conde-González. Entornos personales de aprendizaje móviles: Una revisión sistemática de la literatura. 2017. RIED, 20(2).

[HKM25] A. Huotala, M. Kuutila, and M. Mäntylä. Artefact sharing in software engineering secondary studies. 2025. Information and Software Technology. URL: https://arxiv.org/html/2504.12646v2.

[H+24] A. Huotala and others. The promise and challenges of using LLMs to accelerate the screening process of systematic reviews. 2024. EASE 2024. URL: https://arxiv.org/abs/2404.15667v4.

[K+24] Q. Khraisha and others. Can large language models replace humans in systematic reviews? 2024. Research Synthesis Methods. URL: https://arxiv.org/abs/2310.17526.

[KMB23] B. Kitchenham, L. Madeyski, and D. Budgen. SEGRESS: Software Engineering Guidelines for REporting Secondary Studies. 2023. IEEE Transactions on Software Engineering, 49(3), 1273–1298. URL: https://ebse.webspace.durham.ac.uk/reporting/.

[KBB15] B. A. Kitchenham, D. Budgen, and P. Brereton. Evidence-Based Software Engineering and Systematic Reviews. 2015. Chapman & Hall/CRC. URL: https://www.routledge.com/Evidence-Based-Software-Engineering-and-Systematic-Reviews/Kitchenham-Budgen-Brereton/p/book/9781482228656.

[KC07] Barbara A. Kitchenham and Stuart Charters. Guidelines for performing systematic literature reviews in software engineering. Technical Report EBSE-2007-01, Keele University and Durham University, 2007.

[Li21] Z. Li. Stop building castles on a swamp! The crisis of reproducing automatic search in evidence-based software engineering. 2021. URL: https://arxiv.org/pdf/2103.01381.

[MR14] H. Martín Rodero. La búsqueda bibliográfica, pilar fundamental de la medicina basada en la evidencia. 2014. Tesis, UMH. URL: http://dspace.umh.es/handle/11000/1639.

[MSL20] W. Mengist, T. Soromessa, and G. Legese. Method for conducting systematic literature review and meta-analysis for environmental science research. 2020. MethodsX, 7, 100777.

[M+15] D. Moher and others. PRISMA-P 2015. 2015. Systematic Reviews, 4, 1. URL: https://www.prisma-statement.org/protocols.

[PMB+21] Matthew J. Page, Joanne E. McKenzie, Patrick M. Bossuyt, and others. The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. *BMJ*, 372:n71, 2021. doi:10.1136/bmj.n71.

[Pau13] M. Pautasso. Ten Simple Rules for Writing a Literature Review. 2013. PLoS Computational Biology, 9(7), e1003149.

[PFMM08] K. Petersen, R. Feldt, S. Mujtaba, and M. Mattsson. Systematic mapping studies in software engineering. 2008. EASE 2008. URL: https://www.cse.chalmers.se/\TU\textbackslash{}textasciitildefeldt/publications/petersen\TU\textbackslash{}_ease08\TU\textbackslash{}_sysmap\TU\textbackslash{}_studies\TU\textbackslash{}_in\TU\textbackslash{}_se.pdf.

[PVK15] K. Petersen, S. Vakkalanka, and L. Kuzniarz. Guidelines for conducting systematic mapping studies in software engineering: An update. 2015. Information and Software Technology, 64, 1–18. URL: https://ebse.webspace.durham.ac.uk/?p=466.

[PR05] M. Petticrew and H. Roberts. Systematic reviews in the social sciences: A practical guide. 2005. Wiley.

[R+21a] P. Ralph and others. Empirical Standards for Software Engineering Research. 2021. URL: https://github.com/acmsigsoft/EmpiricalStandards/blob/master/docs/standards/SystematicReviews.md.

[R+21b] M. L. Rethlefsen and others. PRISMA-S. 2021. Systematic Reviews, 10, 39. URL: https://systematicreviewsjournal.biomedcentral.com/articles/10.1186/s13643-020-01542-z.

[SBA+23] Holger J. Schunemann, Sue Brennan, Elie A. Akl, and others. The development methods of official grade articles and requirements for claiming the use of grade: a statement by the grade guidance group. *Journal of Clinical Epidemiology*, 159:79–84, 2023. doi:10.1016/j.jclinepi.2023.05.010.

[SRW+17] Beverley J. Shea, Barnaby C. Reeves, George Wells, and others. Amstar 2: a critical appraisal tool for systematic reviews that include randomised or non-randomised studies of healthcare interventions, or both. *BMJ*, 358:j4008, 2017. doi:10.1136/bmj.j4008.

[Sae01] A. Sáenz. Leer e interpretar una revisión sistemática. 2001. Bol. Soc. Pediatr. Asturias, Cantabria, Castilla y León, 41(177), 215–221.

[TIM25] L. Thode, U. Iftikhar, and D. Mendez. Exploring the use of LLMs for the selection phase in systematic literature studies. 2025. Information and Software Technology, 184, 107757. URL: https://www.fortiss.org/ergebnisse/publikationen/details/exploring-the-use-of-llms-for-the-selection-phase-in-systematic-literature-studies.

[T+24] V. Tran and others. Sensitivity and specificity of using GPT-3.5 Turbo models for title and abstract screening. 2024. Annals of Internal Medicine, 177(6). URL: https://rti.org/publication/sensitivity-specificity-using-gpt-3-5-turbo-models-title-abstract-screening-systematic-reviews-meta.

[T+18] A. C. Tricco and others. PRISMA-ScR. 2018. Annals of Internal Medicine, 169(7), 467–473. URL: https://www.prisma-statement.org/scoping.

[vdS+21] R. van de Schoot and others. An open source machine learning framework for efficient and transparent systematic reviews. 2021. Nature Machine Intelligence, 3, 125–133. URL: https://www.nature.com/articles/s42256-020-00287-7.

[Woh14] C. Wohlin. Guidelines for snowballing in systematic literature studies and a replication in software engineering. 2014. EASE 2014. doi:10.1145/2601248.2601268.

[ZBT11] H. Zhang, M. A. Babar, and P. Tell. Identifying relevant studies in software engineering. 2011. Information and Software Technology, 53(6), 625–637.

[Cochrane] Cochrane. *Cochrane Handbook for Systematic Reviews of Interventions*. Living online handbook; accessed 16 October 2026. URL: https://www.cochrane.org/authors/handbooks-and-manuals/handbook/current.

[RAISERAuiESynthesis25] RAISE: Responsible AI use in Evidence Synthesis. 2025. URL: https://osf.io/fwaud/files/osfstorage.